



Universidade de Brasília
Faculdade de Tecnologia

**Análise e modelagem integrada de
dados de garantia de escoamento**

Gabriel Rabelo de Oliveira

TRABALHO DE CONCLUSÃO DE CURSO
ENGENHARIA MECATRÔNICA

Brasília
2026

Universidade de Brasília
Faculdade de Tecnologia

Análise e modelagem integrada de dados de garantia de escoamento

Gabriel Rabelo de Oliveira

Trabalho de Conclusão de Curso submetido
como requisito parcial para obtenção do grau
de Engenheiro de Controle e Automação.

Orientador: Prof. Dr. Eugênio Libório Feitosa Fortaleza

Brasília
2026

FICHA CATALOGRÁFICA

Oliveira, Gabriel Rabelo de.

Análise e modelagem integrada de dados de garantia de escoamento / Gabriel Rabelo de Oliveira; orientador Eugênio Libório Feitosa Fortaleza. -- Brasília, 2026.

109 p.

Trabalho de Conclusão de Curso (Engenharia Mecatrônica) -- Universidade de Brasília, 2026.

1. Garantia de escoamento. 2. Aprendizado de máquina. 3. Detecção de falhas. 4. Séries temporais multivariadas. 5. Interpretabilidade de modelos. I. Feitosa Fortaleza, Eugênio Libório, orient. II. Título.

Universidade de Brasília
Faculdade de Tecnologia

**Análise e modelagem integrada de dados de garantia de
escoamento**

Gabriel Rabelo de Oliveira

Trabalho de Conclusão de Curso submetido
como requisito parcial para obtenção do grau
de Engenheiro de Controle e Automação.

Trabalho aprovado. Brasília, 14 de Julho de 2026:

Prof. Dr. Eugênio Libório Feitosa Fortaleza
UnB/FT/ENM
Orientador

Prof. Dr. Jones Yudi Mori Alves da Silva
UnB/FT/ENM
Examinador interno

Prof. Dr. Vinícius Vígolo
UnB/FT/ENM
Examinador interno

Me. Vinícius Rafael de Freitas
Kognitus
Examinador externo

Dedico este trabalho à minha família, em especial aos meus pais, Ana Claudia e Divinor, e à minha namorada, Luysa, pelo amor, apoio e incentivo constantes ao longo desta trajetória.

Agradecimentos

Agradeço, primeiramente, aos meus pais, Ana Claudia e Divinor, por todo o apoio, dedicação e incentivo em todas as fases da minha vida, escolar, acadêmica e profissional. Sem o amor, a confiança e os valores que sempre me transmitiram, esta conquista não seria possível.

À minha namorada, Luysa, expresse minha sincera gratidão por sempre acreditar em mim, mesmo nos momentos mais desafiadores, e por todo o suporte emocional, carinho e companheirismo ao longo desta trajetória.

Ao professor Eugênio, meu orientador, agradeço pela disponibilidade, pelas orientações e pela confiança depositada no meu trabalho. Sua experiência foi fundamental para o desenvolvimento deste projeto.

Aos colegas do InfraLab, agradeço pelo ambiente colaborativo e pelos conhecimentos compartilhados, que enriqueceram minha formação e contribuíram para a qualidade deste trabalho.

Por fim, agradeço ao Programa de Recursos Humanos da Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (PRH-ANP-57/UnB) e à Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP), agradeço pelo apoio e financiamento ao longo de toda a pesquisa.

*“If you find that you’re spending almost all your time on theory,
start turning some attention to practical things;
it will improve your theories.
If you find that you’re spending almost all your time on practice,
start turning some attention to theoretical things;
it will improve your practice.”
(Donald Knuth)*

Resumo

A garantia de escoamento é um dos principais desafios da indústria de petróleo, especialmente em ambientes offshore, onde as condições operacionais extremas favorecem fenômenos como formação de hidratos, deposição de parafinas, incrustações e instabilidades de fluxo. A detecção precoce desses eventos é essencial para reduzir perdas de produção e custos de manutenção. Neste contexto, o presente trabalho desenvolve um pipeline de aprendizado de máquina para classificar o estado operacional de poços de petróleo a partir de dados de sensores, utilizando o 3W Dataset 2.0.0 como base de dados.

O pipeline implementado compreende pré-processamento em lotes com limpeza dos dados e normalização por instância, extração de 88 *features* estatísticas por janelamento deslizante de 300 segundos e classificação em 17 estados operacionais: operação normal, eventos ativos e transientes por tipo de falha. Quatro modelos de duas famílias distintas são treinados e comparados: Random Forest e XGBoost, baseados em *features* artesanais, e CNN-LSTM e CNN-1D, que processam as séries temporais brutas. A interpretabilidade das previsões é analisada pelo método SHAP, e uma análise comparativa avalia o impacto de três regimes de filtragem de sinal no desempenho dos classificadores.

Os modelos baseados em *features* estatísticas superaram as redes neurais em aproximadamente 20 pontos percentuais de F1-macro. Essa diferença é atribuída à capacidade das *features* estatísticas de capturar padrões discriminantes que as redes neurais necessitariam de volumes de dados substancialmente maiores para aprender de forma implícita. A análise SHAP confirmou que os modelos aprenderam padrões com significado físico: as *features* mais relevantes para cada classe correspondem consistentemente aos sensores diretamente afetados por aquele tipo de evento. A comparação entre regimes de filtragem revelou impacto modesto nos modelos baseados em *features* e mais expressivo nas redes neurais, evidenciando maior sensibilidade destas ao pré-processamento do sinal.

Os resultados evidenciam a viabilidade do pipeline proposto para o monitoramento contínuo do estado operacional de poços offshore, com previsões fisicamente interpretáveis e desempenho robusto em dados não vistos.

Palavras-chave: Garantia de escoamento; Aprendizado de máquina; Detecção de falhas; Séries temporais multivariadas; Interpretabilidade de modelos.

Abstract

Flow assurance is one of the main challenges in the oil and gas industry, particularly in offshore production systems, where extreme operational conditions favor the occurrence of phenomena such as hydrate formation, wax deposition, scaling, and flow instabilities. Early detection of these events is essential to reduce production losses and maintenance costs. In this context, this work develops a machine learning pipeline to classify the operational state of oil wells from sensor data, using the 3W Dataset 2.0.0 as the data source.

The implemented pipeline comprises batch preprocessing with data cleaning and per-instance normalization, extraction of 88 statistical features via a 300-second sliding window, and classification into 17 operational states: normal operation, active events, and transients by fault type. Four models from two distinct families are trained and compared: Random Forest and XGBoost, based on handcrafted features, and CNN-LSTM and CNN-1D, which process raw time series directly. Model interpretability is analyzed using the SHAP method, and a comparative analysis evaluates the impact of three signal filtering regimes on classifier performance.

The statistical feature models outperformed the neural networks by approximately 20 percentage points in F1-macro. This gap is attributed to the ability of statistical features to capture discriminative patterns that neural networks would require substantially larger datasets to learn implicitly. SHAP analysis confirmed that the models learned physically meaningful patterns: the most relevant features for each class consistently correspond to the sensors directly affected by that fault type. The comparison between filtering regimes revealed modest impact on feature-based models and a more pronounced impact on neural networks, indicating greater sensitivity of the latter to signal preprocessing.

These results demonstrate the viability of the proposed pipeline for continuous monitoring of the operational state of offshore wells, with physically interpretable predictions and robust performance on unseen data.

Keywords: Flow assurance; Machine learning; Fault detection; Multivariate time series; Model interpretability.

Lista de figuras

Figura 2.1	Esquema de um sistema de produção submarino de petróleo.	22
Figura 2.2	Exemplo de dinâmica para instância da Classe 0 (Operação Normal). .	28
Figura 2.3	Exemplo da dinâmica da falha por Hidrato na Linha de Produção . . .	29
Figura 2.4	Exemplo da dinâmica da falha por Restrição súbita no PCK	30
Figura 2.5	Exemplo 1 da dinâmica da falha por Hidrato na Linha de Serviço	31
Figura 2.6	Exemplo 2 da dinâmica da falha por Hidrato na Linha de Serviço	31
Figura 2.7	Distribuição da duração das instâncias por classe de falha.	32
Figura 2.8	Percentual de dados faltantes por sensor e classe de falha.	33
Figura 2.9	Fração de amostras com leitura válida por sensor no 3W Dataset 2.0.0. .	34
Figura 2.10	Cobertura por par de sensores no 3W Dataset.	36
Figura 2.11	Matriz de correlação de Pearson entre os sensores contínuos do 3W Dataset.	37
Figura 2.12	Pairplot dos sensores principais do 3W Dataset, com 500 amostras por classe de falha.	38
Figura 2.13	Variância explicada por componente principal - sensores contínuos do 3W Dataset.	39
Figura 2.14	<i>Loadings</i> das componentes principais - contribuição de cada sensor por componente.	40
Figura 2.15	Ranking de importância global dos sensores por PCA.	41
Figura 2.16	Imprecisão de rotulagem em instância real da Classe 6 (Restrição Rápida no PCK).	42
Figura 3.1	Exemplo de estrutura de uma árvore de decisão com nós de decisão, arestas e nós folha.	44
Figura 3.2	Estrutura do Random Forest.	46
Figura 3.3	Arquitetura sequencial do XGBoost	48
Figura 3.4	Arquitetura típica de rede convolucional 1D.	49
Figura 3.5	Arquitetura Fully Convolutional Network (FCN).	50
Figura 3.6	Estrutura de uma célula LSTM.	52
Figura 3.7	Arquitetura CNN-LSTM: blocos convolucionais com MaxPooling comprimem a sequência temporal, seguidos de camada LSTM, Dropout e classificação softmax.	53
Figura 3.8	Ilustração da validação cruzada com 5 folds.	54
Figura 3.9	Estrutura da validação cruzada aninhada com loops externo e interno. .	55
Figura 4.1	Fluxograma metodológico do pipeline de classificação de estado operacional.	59

Figura 4.2	Comparação visual dos três métodos de filtragem sobre sinais do poço WELL-00028 (Classe 8 – Hidrato na Linha de Produção).	68
Figura 5.1	Matriz de confusão do RF (filtro Gaussiano, $\sigma = 2,0$, avaliação OOF). . .	71
Figura 5.2	Matriz de confusão do XGBoost (filtro Gaussiano, $\sigma = 2,0$, avaliação OOF). . .	72
Figura 5.3	Matriz de confusão da CNN-LSTM (filtro Gaussiano, $\sigma = 2,0$, avaliação OOF).	73
Figura 5.4	Matriz de confusão da CNN-1D (FCN, filtro Gaussiano, $\sigma = 2,0$, avaliação OOF).	74
Figura 5.5	Importância global por sensor (média dos valores SHAP absolutos). . .	78
Figura 5.6	Top 20 features por importância MDI — RF e XGBoost.	79
Figura 5.7	Valores SHAP para a classe 8 (Hidrato na Linha de Produção, Ativo) — RF vs XGBoost.	80
Figura 5.8	Valores SHAP para a classe 108 (Hidrato na Linha de Produção, Transiente) — RF vs XGBoost.	81
Figura 5.9	Valores SHAP para a classe 9 (Hidrato na Linha de Serviço, Ativo) — RF vs XGBoost.	82
Figura 5.10	Valores SHAP para a classe 109 (Hidrato na Linha de Serviço, Transiente) — RF vs XGBoost.	83
Figura C.1	Valores SHAP para a classe 0 (Normal) — RF vs XGBoost.	97
Figura C.2	Valores SHAP para a classe 1 (BSW, Ativo) — RF vs XGBoost.	97
Figura C.3	Valores SHAP para a classe 2 (DHSV, Ativo) — RF vs XGBoost.	98
Figura C.4	Valores SHAP para a classe 3 (Golfadas, Ativo) — RF vs XGBoost. . . .	98
Figura C.5	Valores SHAP para a classe 4 (Instabilidade de Fluxo, Ativo) — RF vs XGBoost.	98
Figura C.6	Valores SHAP para a classe 5 (Perda Rápida de Produtividade, Ativo) — RF vs XGBoost.	99
Figura C.7	Valores SHAP para a classe 6 (Restrição no PCK, Ativo) — RF vs XGBoost. . .	99
Figura C.8	Valores SHAP para a classe 7 (Incrustação no PCK, Ativo) — RF vs XGBoost. . .	99
Figura C.9	Valores SHAP para a classe 8 (Hidrato na Linha de Produção, Ativo) — RF vs XGBoost.	100
Figura C.10	Valores SHAP para a classe 9 (Hidrato na Linha de Serviço, Ativo) — RF vs XGBoost.	100
Figura C.11	Valores SHAP para a classe 101 (BSW, Transiente) — RF vs XGBoost. . .	100
Figura C.12	Valores SHAP para a classe 102 (DHSV, Transiente) — RF vs XGBoost. . .	101
Figura C.13	Valores SHAP para a classe 105 (Perda Rápida de Produtividade, Transiente) — RF vs XGBoost.	101
Figura C.14	Valores SHAP para a classe 106 (Restrição no PCK, Transiente) — RF vs XGBoost.	101

Figura C.15	Valores SHAP para a classe 107 (Incrustação no PCK, Transiente) — RF vs XGBoost.	102
Figura C.16	Valores SHAP para a classe 108 (Hidrato na Linha de Produção, Transiente) — RF vs XGBoost.	102
Figura C.17	Valores SHAP para a classe 109 (Hidrato na Linha de Serviço, Transiente) — RF vs XGBoost.	102
Figura D.1	Matriz de confusão do RF (filtro Gaussiano, $\sigma = 2,0$).	103
Figura D.2	Matriz de confusão do XGBoost (filtro Gaussiano, $\sigma = 2,0$).	104
Figura D.3	Matriz de confusão do XGBoost (sem filtro).	105
Figura D.4	Matriz de confusão do XGBoost (filtro estatístico, $\sigma = 0,5$).	106
Figura D.5	Matriz de confusão da CNN-LSTM (filtro Gaussiano, $\sigma = 2,0$).	107
Figura D.6	Matriz de confusão da CNN-LSTM (filtro estatístico, $\sigma = 0,5$).	108
Figura D.7	Matriz de confusão da CNN-1D (FCN, filtro Gaussiano, $\sigma = 2,0$).	109

Lista de tabelas

Tabela 2.1	Variáveis de abertura e estado de válvulas	24
Tabela 2.2	Variáveis de pressão	25
Tabela 2.3	Variáveis de temperatura	25
Tabela 2.4	Variáveis de vazão	25
Tabela 2.5	Distribuição de instâncias por classe e tipo de origem no 3W Dataset 2.0.0.	26
Tabela 2.6	Distribuição de episódios reais por poço físico e classe de falha.	35
Tabela 4.1	Sensores selecionados para o pipeline de classificação, adaptada das Tabelas 2.2 a 2.4.	61
Tabela 4.2	Estatísticas extraídas por sensor em cada janela deslizante (88 features no total).	62
Tabela 4.3	Classes do estado operacional utilizadas na rotulagem das janelas.	63
Tabela 4.4	Espaços de busca de hiperparâmetros por modelo.	66
Tabela 4.5	Configuração de treinamento das redes neurais CNN-1D e CNN-LSTM.	66
Tabela 4.6	Configurações comparadas na análise de métodos de filtragem de sinal.	67
Tabela 5.1	Métricas globais dos modelos avaliados (filtro Gaussiano, $\sigma = 2,0$).	69
Tabela 5.2	F1-score por classe operacional para todos os modelos (filtro Gaussiano).	70
Tabela 5.3	Métricas globais do XGBoost para os três regimes de filtragem de sinal.	76
Tabela 5.4	F1-score por classe operacional para os três regimes de filtragem (XGBoost).	76
Tabela 5.5	Métricas globais da CNN-LSTM para os três regimes de filtragem de sinal.	77
Tabela 5.6	F1-score por classe operacional para os três regimes de filtragem (CNN-LSTM).	77
Tabela A.1	Espaços de busca de hiperparâmetros por modelo.	94
Tabela A.2	Espaço de busca e hiperparâmetros selecionados pelo <i>Optuna</i> (CNN-LSTM).	95
Tabela A.3	Arquitetura e configurações da CNN-1D (FCN).	95
Tabela B.1	Distribuição das janelas por estado operacional (filtro Gaussiano, $\sigma = 2,0$).	96

Lista de abreviaturas e siglas

3W	Three-Well Dataset
AI	Artificial Intelligence
BSW	Basic Sediment and Water
CNN	Rede Neural Convolucional (<i>Convolutional Neural Network</i>)
CV	Validação Cruzada (<i>Cross-Validation</i>)
DHSV	Downhole Safety Valve
DT	Árvore de Decisão (<i>Decision Tree</i>)
FCN	Rede Totalmente Convolucional (<i>Fully Convolutional Network</i>)
FN	Falso Negativo (<i>False Negative</i>)
FP	Falso Positivo (<i>False Positive</i>)
FPSO	Floating Production Storage and Offloading
GARESC	Garantia de Escoamento
GLCK	Gas Lift Choke
IA	Inteligência Artificial
IoT	Internet das Coisas (<i>Internet of Things</i>)
IQR	<i>Interquartile Range</i> (Amplitude Interquartil)
LR	<i>Learning Rate</i> (Taxa de Aprendizado)
LSTM	Long Short-Term Memory
MDI	<i>Mean Decrease in Impurity</i>
ML	Machine Learning
MTS	Multivariate Time Series
NaN	<i>Not A Number</i>
OLGA	Oil and Gas Simulator
OOF	<i>Out-of-Fold</i>
PCK	Production Choke
PDG	Permanent Downhole Gauge
RF	Random Forest
RNN	Rede Neural Recorrente (<i>Recurrent Neural Network</i>)
SHAP	<i>Shapley Additive Explanations</i>
TP	Verdadeiro Positivo (<i>True Positive</i>)
TPT	Temperature and Pressure Transducer
XAI	<i>Explainable Artificial Intelligence</i>
XGB	Extreme Gradient Boosting

Sumário

1	Introdução	17
1.1	Contextualização: Indústria 4.0 e Ciência de Dados	17
1.2	Garantia de Escoamento na Indústria do Petróleo	17
1.3	Inteligência Artificial e Modelagem de Dados	18
1.4	Objetivos do Trabalho	19
1.5	Trabalhos Relacionados	20
2	Base de Dados 3W	22
2.1	Descrição Geral	22
2.2	Composição dos Dados	24
2.2.1	Variáveis Monitoradas	24
2.2.2	Tipos de Instâncias e Distribuição de Classes	25
2.2.3	Eventos e Rotulagem	26
2.3	Análise Exploratória de Dados	27
2.3.1	Comportamento Dinâmico das Séries Temporais	27
2.3.2	Distribuição e Disponibilidade dos Dados	32
2.3.3	Correlações Cruzadas	35
2.3.4	Pairplot dos Sensores Principais	37
2.3.5	Análise de Componentes Principais	38
2.4	Desafios e Características Intrínsecas	41
3	Fundamentação Teórica	44
3.1	Árvores de Decisão	44
3.1.1	Critério de Divisão	45
3.1.2	Overfitting e Alta Variância	45
3.2	Bagging e Random Forest	45
3.2.1	Amostragem Bootstrap e Bagging	45
3.2.2	Random Forest	46
3.3	Gradient Boosting e XGBoost	47
3.3.1	Boosting Sequencial	47
3.3.2	XGBoost	47
3.4	Redes Convolucionais 1D	48
3.4.1	Convolução 1D	49
3.4.2	Normalização em Lote	49
3.4.3	Global Average Pooling e Arquitetura FCN	50
3.5	Redes Recorrentes e LSTM	51

3.5.1	Redes Neurais Recorrentes e o Gradiente Desvanecente	51
3.5.2	Long Short-Term Memory (LSTM)	51
3.5.3	Arquitetura CNN-LSTM	52
3.6	Validação Cruzada e GroupKFold	53
3.6.1	Validação Cruzada k-Fold	53
3.6.2	Data Leakage em Séries Temporais	54
3.6.3	GroupKFold	54
3.6.4	Validação Cruzada Aninhada	55
3.7	Filtragem de Sinal	55
3.7.1	Filtro Gaussiano	56
3.7.2	Filtro Estatístico Adaptativo	56
3.8	Métricas de Avaliação	57
4	Metodologia	58
4.1	Visão Geral do Pipeline	58
4.2	Pré-processamento dos Dados	60
4.2.1	Leitura em Lotes e Limpeza	60
4.2.2	Seleção de Sensores	60
4.2.3	Normalização por Instância	61
4.2.4	Filtragem de Sinal	61
4.3	Janelamento Deslizante e Extração de Features	62
4.3.1	Segmentação por Janela Deslizante	62
4.3.2	Features Extraídas	62
4.4	Rotulagem de Janelas	63
4.5	Treinamento e Validação	64
4.5.1	Estratégia de Validação Cruzada	64
4.5.2	Configuração por Modelo	64
4.6	Interpretabilidade com SHAP	66
4.7	Comparação de Métodos de Filtragem	67
5	Resultados e Análises	69
5.1	Comparação entre Modelos	69
5.1.1	Métricas Globais	69
5.1.2	Desempenho por Classe	69
5.1.3	Análise das Matrizes de Confusão	70
5.1.4	A Classe 7 — Incrustação no PCK (Ativo)	74
5.1.5	Análise: Features Artesanais vs Representações Aprendidas	75
5.2	Análise Comparativa de Métodos de Filtragem	75
5.2.1	Métricas Globais dos Três Regimes	75
5.2.2	Análise por Classe	76

5.2.3	Comparação para a CNN-LSTM	77
5.3	Análise de Interpretabilidade	78
5.3.1	Importância Global por Sensor	78
5.3.2	Importância Global das Features	79
5.3.3	SHAP para Eventos de Formação de Hidrato	80
6	Conclusões	85
6.1	Síntese dos Resultados	85
6.2	Contribuições	86
6.3	Limitações	86
6.4	Trabalhos Futuros	87
	Referências	88
	Apêndices	93
	Apêndice A Hiperparâmetros Otimizados	94
A.1	Random Forest e XGBoost	94
A.2	CNN-LSTM	94
A.3	CNN-1D (FCN)	95
	Apêndice B Distribuição das Classes no Conjunto de Dados	96
	Apêndice C Valores SHAP para Todas as Classes Operacionais	97
C.1	Estados Ativos	97
C.2	Estados Transientes	100
	Apêndice D Matrizes de Confusão	103

1 Introdução

Este documento apresenta o desenvolvimento de um projeto de pesquisa voltado à análise e modelagem integrada de dados relacionados à garantia de escoamento em sistemas de produção de petróleo. A proposta insere-se no contexto da transformação digital e da adoção de tecnologias da *Indústria 4.0*, que têm impulsionado o uso de *Ciência de Dados* e *Inteligência Artificial (IA)* para aprimorar a eficiência e a segurança de processos industriais complexos.

1.1 Contextualização: Indústria 4.0 e Ciência de Dados

Nas últimas décadas, a chamada *Indústria 4.0* tem promovido uma transformação profunda na maneira como sistemas industriais são projetados, operados e monitorados (Lu, 2017). Essa nova era tecnológica é caracterizada pela convergência entre tecnologias emergentes, como a *Internet das Coisas (IoT)*, computação em nuvem, sistemas ciberfísicos e *Inteligência Artificial*, que permitem a comunicação autônoma e a integração inteligente entre máquinas, processos e pessoas.

Com a digitalização crescente das operações, um imenso volume de dados passou a ser gerado continuamente por sensores, atuadores e sistemas de controle. Nesse cenário, Donoho (2017) define a *Ciência de Dados* como uma disciplina dedicada à extração de conhecimento e à descoberta de padrões a partir de dados brutos. Utilizando técnicas estatísticas e de aprendizado de máquina, essa área possibilita identificar correlações e tendências que auxiliam na otimização de processos e na tomada de decisões estratégicas baseadas em evidências.

Na indústria do petróleo, tais avanços têm sido aplicados em todas as etapas do ciclo produtivo, da exploração e perfuração (Sircar *et al.*, 2021) até a produção e o escoamento (Bikmukhametov; Jäschke, 2020; Vargas *et al.*, 2019), possibilitando o desenvolvimento de sistemas mais inteligentes. Nesse sentido, a integração entre engenharia e ciência de dados tem se tornado um pilar essencial para o avanço tecnológico e a melhoria da eficiência operacional, especialmente em ambientes complexos como os sistemas offshore.

1.2 Garantia de Escoamento na Indústria do Petróleo

A *garantia de escoamento (GARESC)* é uma área crítica da engenharia de produção de petróleo, voltada a assegurar que os fluidos produzidos, compostos por misturas de óleo,

gás, água e, por vezes, partículas sólidas, sejam transportados de forma segura e contínua do reservatório até as unidades de processamento (Oliveira; Gonçalves; Marques, 2018).

No Brasil, a relevância dessa área é amplificada pelas operações na camada pré-sal, em lâminas d'água superiores a 2.000 metros. Nessas condições, as baixas temperaturas e as altas pressões no leito marinho favorecem a ocorrência de fenômenos físico-químicos que podem comprometer o fluxo, como a formação de hidratos (Sloan; Koh, 2008), a deposição de parafinas, a precipitação de asfaltenos e o surgimento de incrustações (Oliveira; Gonçalves; Marques, 2018). Esses fenômenos podem causar obstruções nas linhas de escoamento, levando a interrupções operacionais, redução de produtividade e aumento dos custos de manutenção.

A análise e o controle desses fenômenos exigem uma abordagem multidisciplinar, envolvendo fundamentos de escoamento multifásico, termodinâmica, química e ciência de materiais. Contudo, a complexidade dos processos e a heterogeneidade dos dados disponíveis tornam o diagnóstico e a previsão das ocorrências um grande desafio. É nesse contexto que a aplicação de técnicas de ciência de dados e inteligência artificial se mostra promissora, oferecendo ferramentas para compreender melhor as causas e os efeitos dos eventos de GARESC e aprimorar sua gestão.

1.3 Inteligência Artificial e Modelagem de Dados

A *Inteligência Artificial* é um campo da ciência da computação voltado à criação de algoritmos e sistemas capazes de realizar tarefas que normalmente exigiriam inteligência humana, como raciocínio, aprendizado e tomada de decisão (Russell; Norvig, 2020). No âmbito industrial, a IA tem desempenhado papel central na automação de processos e na análise de grandes volumes de dados operacionais.

Dentro da IA, o *Aprendizado de Máquina* (*Machine Learning*) ocupa posição de destaque por possibilitar que modelos computacionais aprendam padrões complexos a partir de exemplos históricos, sem a necessidade de instruções explícitas (Mitchell, 1997). De forma geral, os métodos de aprendizado de máquina são classificados em três categorias principais (Goodfellow; Bengio; Courville, 2016):

- **Aprendizado supervisionado:** utiliza conjuntos de dados rotulados para treinar modelos capazes de realizar previsões em novos cenários. É amplamente empregado em tarefas de regressão e classificação;
- **Aprendizado não supervisionado:** busca identificar estruturas ocultas ou agrupamentos naturais nos dados, sendo útil para análise exploratória, detecção de anomalias e redução de dimensionalidade;
- **Aprendizado por reforço:** baseia-se na interação entre um agente e o ambiente, permitindo que o sistema aprenda estratégias ótimas por meio de tentativa e erro,

buscando maximizar recompensas acumuladas.

Para o tratamento de dados temporais, como medições de sensores e séries históricas de variáveis operacionais, duas abordagens principais se destacam na literatura. A primeira consiste em extrair, manualmente, features estatísticas das séries, como média, desvio padrão e taxa de variação, e alimentar modelos de ensemble como *Random Forest* (RF) (Breiman, 2001) e *XGBoost* (Chen; Guestrin, 2016). Esses modelos são computacionalmente eficientes e altamente interpretáveis por meio de técnicas como o SHAP (Lundberg; Lee, 2017) (*SHapley Additive exPlanations*).

A segunda abordagem utiliza modelos de redes neurais diretamente sobre as séries temporais brutas, eliminando a necessidade de engenharia manual de features. Redes recorrentes, como *Long Short-Term Memory* (LSTM) (Hochreiter; Schmidhuber, 1997) e *Gated Recurrent Unit* (GRU) (Cho *et al.*, 2014), são eficazes na captura de dependências temporais de longo prazo, enquanto redes convolucionais unidimensionais, especialmente arquiteturas como a *Fully Convolutional Network* (FCN) (Wang; Yan; Oates, 2017), destacam-se na extração automática de padrões locais ao longo do tempo, com maior eficiência computacional e boa capacidade de generalização.

Neste trabalho, as duas abordagens são avaliadas e comparadas diretamente, permitindo quantificar o ganho obtido pelo conhecimento especializado embutido pela engenharia de features em relação às representações aprendidas automaticamente pelas redes neurais, no contexto da detecção de falhas em poços de petróleo.

Em poços de petróleo, o mesmo tipo de falha pode manifestar-se de formas distintas em diferentes contextos de produção, tornando insuficientes abordagens baseadas em limiares fixos e exigindo a análise simultânea de múltiplos sensores. A combinação entre modelos de aprendizado de máquina e o conhecimento físico dos processos responde a esse desafio, criando soluções mais robustas e interpretáveis que unem a capacidade de generalização dos métodos estatísticos à fundamentação teórica dos fenômenos operacionais.

1.4 Objetivos do Trabalho

O objetivo principal deste trabalho é desenvolver e avaliar um pipeline de aprendizado de máquina para detecção e classificação de falhas em poços de petróleo, a partir de dados de sensores, utilizando o 3W Dataset como base de dados.

De forma mais específica, pretende-se:

- Comparar diferentes abordagens de aprendizado de máquina na classificação de estados operacionais de poços de petróleo;
- Quantificar o impacto de diferentes regimes de filtragem de sinal no desempenho dos classificadores;

- Identificar quais sensores e padrões estatísticos são mais relevantes para cada tipo de falha, tornando as previsões interpretáveis.

1.5 Trabalhos Relacionados

A publicação do 3W Dataset impulsionou o desenvolvimento de diversas abordagens para o gerenciamento de eventos anômalos em poços de petróleo, variando desde técnicas não supervisionadas até arquiteturas complexas de aprendizado profundo. Esta seção discute trabalhos relevantes que fundamentam o estado da arte e destacam os desafios ainda existentes na área.

Investigando o potencial de modelos generativos para a detecção de anomalias, [Rosa \(2020\)](#) explorou o uso de Autoencoders (AE) e Variational Autoencoders (VAE). A premissa do autor baseou-se na hipótese de reconstrução: um modelo treinado exclusivamente com dados de operação normal teria dificuldades em reconstruir dados contendo falhas, gerando um erro residual elevado que serviria como indicador de anomalia. Ao comparar as duas arquiteturas, o estudo concluiu que, embora os VAEs ofereçam uma modelagem probabilística robusta do espaço latente, os Autoencoders convencionais apresentaram um desempenho superior (melhor F1-Score) na detecção de falhas abruptas como o fechamento espúrio de DHSV e o aumento de BSW. Contudo, o trabalho evidenciou a dificuldade em definir limiares de erro universais para todos os tipos de eventos.

Abordando a complexidade inerente à dinâmica dos poços, [Machado \(2024\)](#) identificou que a alta variabilidade intra-classe, em que o mesmo tipo de falha apresenta assinaturas temporais distintas em diferentes poços, é um dos principais fatores de degradação de modelos preditivos. Para mitigar esse problema, o autor propôs uma metodologia de Classificação de Classe Única (*One-Class Classification*) aprimorada por agrupamento dinâmico. Utilizando a medida de similaridade Dynamic Time Warping (DTW) combinada com DBA Barycenter Averaging, redes neurais recorrentes Long Short-Term Memory foram treinadas em diferentes *clusters* de comportamento. Os resultados demonstraram que segmentar os dados por similaridade morfológica, em vez de treinar um modelo genérico global, pode elevar a performance de detecção em mais de 20% em cenários críticos.

Mais recentemente, avançando para estratégias supervisionadas de alto desempenho, [Benedito \(2025\)](#) desenvolveu um sistema baseado em Ensemble Learning (Aprendizado de Conjunto). Em contraste com as abordagens de aprendizado profundo, o autor combinou dois algoritmos de Machine Learning: Regressão Logística e LightGBM, estruturados em um Voting Classifier. A hipótese defendida foi a de que a agregação de modelos robustos (*bagging* e *boosting*) ofereceria maior estabilidade e eficiência computacional. O sistema proposto alcançou uma acurácia global de 99,65% no conjunto de teste, demonstrando alta sensibilidade (> 97%) mesmo para falhas complexas.

O presente trabalho se diferencia ao reunir quatro aspectos pouco explorados em conjunto na literatura do 3W Dataset: (i) classificação em 17 estados operacionais distintos, incluindo eventos ativos e transientes por tipo de falha; (ii) comparação direta entre modelos baseados em árvores (*Random Forest* e *XGBoost*) e redes neurais (CNN-1D e CNN-LSTM), quantificando o ganho de cada abordagem; (iii) avaliação do impacto de três regimes de filtragem de sinal no desempenho dos modelos; e (iv) interpretabilidade via SHAP, identificando quais sensores e features mais influenciam cada estado operacional.

2 Base de Dados 3W


2.1 Descrição Geral

A base de dados *3W Dataset 2.0.0* (Vargas *et al.*, 2025) visa promover o avanço de métodos de IA e aprendizado de máquina aplicados à detecção preventiva de eventos indesejáveis em poços de petróleo.

O nome "3W" deriva das três origens dos dados: instâncias reais, simuladas e desenhadas manualmente por especialistas. Essa combinação permite representar de forma abrangente os comportamentos dinâmicos e anomalias observadas em sistemas reais de produção offshore.

Atualmente, o dataset é composto por 2.228 instâncias provenientes de 40 poços reais, abrangendo 10 tipos de eventos operacionais e incluindo tanto condições normais quanto falhas críticas. Cada instância é uma série temporal multivariada, amostrada a uma frequência fixa de 1 Hz, representando a evolução temporal de múltiplas variáveis de processo. O dataset é disponibilizado publicamente no repositório oficial da Petrobras no GitHub: <https://github.com/petrobras/3W>.

Figura 2.1 – Esquema de um sistema de produção submarino de petróleo.



Fonte: Retirado de Vargas *et al.* (2025).

A Figura 2.1 ilustra um sistema típico de produção submarina de petróleo, composto por diferentes subsistemas que trabalham em conjunto para transportar os fluidos do reservatório até as instalações de processamento na superfície (Bai; Bai, 2012).

O processo tem início no reservatório, uma formação rochosa porosa localizada a grande profundidade, onde o petróleo, o gás e a água estão armazenados sob alta pressão. Essa pressão natural impulsiona os fluidos em direção à superfície através do poço. À medida que a produção avança e a pressão do reservatório declina, técnicas de elevação artificial tornam-se necessárias para manter o escoamento. Uma das mais utilizadas em operações offshore é o *gás lift*, que injeta gás comprimido pela linha de serviço até o interior do poço, reduzindo a densidade da coluna de fluidos e auxiliando na elevação. Esse sistema é controlado pela válvula de gás lift (GLCK) e pela válvula de fechamento do gás lift (SDV-GL).

Na cabeça do poço, no leito marinho, encontra-se a *árvore de natal molhada* (ANM), um conjunto de válvulas e conexões responsável por controlar o fluxo de produção e garantir a segurança operacional do poço (Bai; Bai, 2012). A válvula de segurança descendente (DHSV), instalada no interior do poço, fecha automaticamente em situações de emergência para isolar o reservatório. As válvulas mestras de produção (PMV) e do anular (AMV) controlam o escoamento das respectivas linhas, enquanto as válvulas laterais (PWV e AWP) permitem o acesso a cada linha individualmente. O *choke* de produção (PCK) regula a vazão e a pressão a jusante do poço, sendo um dos pontos mais críticos para o monitoramento do escoamento. As válvulas de cruzamento (PXO e XO) permitem desviar o fluxo entre as linhas de produção e de serviço quando necessário.

A produção sai da árvore de natal molhada e percorre linhas de escoamento até o *Floating Production Storage and Offloading* (FPSO), uma plataforma flutuante ancorada próxima ao campo. No FPSO, os fluidos passam pelo processamento primário, onde ocorre a separação de óleo, gás e água, seguida do armazenamento temporário do óleo até o transbordo para navios-tanque.

Em cada etapa desse percurso, fenômenos físicos e químicos podem comprometer a continuidade do escoamento. As baixas temperaturas e altas pressões nas linhas submarinas favorecem a formação de hidratos e a deposição de parafinas, que podem obstruir parcial ou totalmente o fluxo. Variações na composição do fluido produzido causam, em alguns casos, aumento abrupto do teor de água e sedimentos (BSW) ou a precipitação de incrustações minerais nos equipamentos de controle, como o PCK. Desequilíbrios entre as fases gás e líquido dão origem a golfadas severas e instabilidade de fluxo, provocando grandes oscilações de pressão e vazão. Falhas mecânicas ou operacionais em válvulas críticas, como fechamentos espúrios da DHSV ou restrições súbitas no choke de produção, podem ainda interromper o fluxo de forma abrupta.

Para detectar e acompanhar essas ocorrências, sensores distribuídos registram continuamente as variáveis operacionais do sistema. O *Permanent Downhole Gauge* (PDG)

mede pressão e temperatura no fundo do poço, próximo ao reservatório. O *Temperature and Pressure Transducer* (TPT), posicionado na árvore de natal molhada, registra as condições no leito marinho. Medidores de pressão a montante e a jusante do *choke* de produção monitoram a queda de pressão nesse ponto, enquanto sensores de temperatura na linha de produção e medidores de vazão de gás lift e da bomba de serviço completam o sistema de instrumentação. É o conjunto dessas medições que constitui as variáveis monitoradas na base 3W, descritas na Seção 2.2.1.

2.2 Composição dos Dados

2.2.1 Variáveis Monitoradas

As variáveis do *3W Dataset* correspondem aos principais pontos de instrumentação de um sistema de produção submarino, abrangendo sensores de pressão, temperatura, vazão e abertura de válvulas distribuídos ao longo do poço e das linhas de escoamento.

Tabela 2.1 – Variáveis de abertura e estado de válvulas no 3W Dataset 2.0.0

Nome	Descrição	Posição
ABER-CKGL	Abertura do choke de gás lift (GLCK)	1.1
ABER-CKP	Abertura do choke de produção (PCK)	2.1
ESTADO-DHSV	Estado da válvula de segurança descendente (DHSV)	3.1
ESTADO-M1	Estado da válvula mestra de produção (PMV)	4.1
ESTADO-M2	Estado da válvula mestra do anular (AMV)	5.1
ESTADO-PXO	Estado da válvula de cruzamento (PXO)	6.1
ESTADO-SDV-GL	Estado da válvula de fechamento do gás lift (SDV)	7.1
ESTADO-SDV-P	Estado da válvula de fechamento da produção (SDV)	8.1
ESTADO-W1	Estado da válvula lateral de produção (PWV)	9.1
ESTADO-W2	Estado da válvula lateral do anular (AWV)	10.1
ESTADO-XO	Estado da válvula de cruzamento (XO)	11.1

Fonte: Adaptado de [Vargas et al. \(2025\)](#)

Tabela 2.2 – Variáveis de pressão no 3W Dataset 2.0.0

Nome	Descrição	Posição
P-ANULAR	Pressão no espaço anular do poço	12.1
P-JUS-BS	Pressão jusante da bomba de serviço (SP)	13.1
P-JUS-CKGL	Pressão jusante do choke de gás lift	1.2
P-JUS-CKP	Pressão jusante do choke de produção	2.2
P-MON-CKGL	Pressão montante do choke de gás lift	1.3
P-MON-CKP	Pressão montante do choke de produção	2.3
P-MON-SDV-P	Pressão montante da válvula de fechamento da produção (SDV)	8.2
P-PDG	Pressão de fundo medida pelo PDG	14.1
P-PT-P	Pressão na árvore de natal molhada jusante da válvula PWV	4.2
P-TPT	Pressão na árvore de natal molhada no TPT	15.1

Fonte: Adaptado de [Vargas et al. \(2025\)](#)

Tabela 2.3 – Variáveis de temperatura no 3W Dataset 2.0.0

Nome	Descrição	Posição
T-JUS-CKP	Temperatura jusante do choke de produção	2.4
T-MON-CKP	Temperatura montante do choke de produção	2.5
T-PDG	Temperatura de fundo medida pelo PDG	14.2
T-TPT	Temperatura na árvore de natal molhada no TPT	15.2

Fonte: Adaptado de [Vargas et al. \(2025\)](#)

Tabela 2.4 – Variáveis de vazão no 3W Dataset 2.0.0

Nome	Descrição	Posição
QBS	Vazão na bomba de serviço (SP)	13.2
QGL	Vazão do gás lift	13.3

Fonte: Adaptado de [Vargas et al. \(2025\)](#)

2.2.2 Tipos de Instâncias e Distribuição de Classes

Cada instância é um arquivo Apache Parquet ([Apache Software Foundation, 2013](#)) com três possíveis origens:

1. **Instâncias Reais** (WELL-[ID].parquet): extraídas de poços reais monitorados pela Petrobras, com rótulos revisados por especialistas;

2. **Instâncias Simuladas** (SIMULATED-[ID].parquet): geradas pelo simulador *OLGA*, com parâmetros calibrados para reproduzir comportamentos operacionais e falhas específicas;
3. **Instâncias Desenhadas Manualmente** (DRAWN-[ID].parquet): construídas por especialistas a partir do comportamento esperado das variáveis em cada tipo de evento.

Cada instância do 3W é classificada de 0 a 9, de acordo com o tipo de evento de escoamento que apresenta. A Tabela 2.5 mostra a quantidade de instâncias por classe e por origem.

Tabela 2.5 – Distribuição de instâncias por classe e tipo de origem no 3W Dataset 2.0.0.

Classe	Evento	Total	Reais	Simuladas	Desenhadas
0	Normal	594	594	0	0
1	Aumento Abrupto de BSW	128	4	114	10
2	Fechamento Espúrio da DHSV	38	22	16	0
3	Golfadas Severas	106	32	74	0
4	Instabilidade de Fluxo	343	343	0	0
5	Perda Rápida de Produtividade	450	11	439	0
6	Restrição Rápida no PCK	221	6	215	0
7	Incrustação no PCK	46	36	0	10
8	Hidrato na Linha de Produção	95	14	81	0
9	Hidrato na Linha de Serviço	207	57	150	0
Total		2.228	1.119	1.089	20

Fonte: Adaptado de Vargas *et al.* (2025).

2.2.3 Eventos e Rotulagem

Cada amostra do dataset recebe dois tipos de rótulo: o **rótulo de classe** (*class label*), que identifica o tipo de evento associado ao poço, e o **rótulo de estado** (*state label*), que descreve a situação operacional do poço em cada instante de tempo, como produção, fechamento, reinício ou despressurização. Este segundo rótulo não é utilizado neste trabalho, pois o objetivo é classificar o tipo de evento de falha a partir dos dados de sensores, tarefa para a qual o rótulo de classe é suficiente.

A seguir, é apresentada uma breve explicação de cada evento, conforme descrito por Vargas *et al.* (2019):

- **Aumento abrupto de BSW (Classe 1):** ocorre quando há entrada súbita de água e sedimentos, provocando aumento do teor de água na produção e queda da eficiência do sistema;

- **Fechamento espúrio da DHSV (Classe 2):** fechamento inesperado da válvula de segurança, resultando em bloqueio do escoamento e pressurização anômala na coluna;
- **Severe Slugging (Classe 3):** padrão cíclico de escoamento intermitente, alternando entre bolhas de gás e colunas líquidas, causando grandes oscilações de pressão e vazão;
- **Instabilidade de fluxo (Classe 4):** variações não periódicas de vazão e pressão devido a desequilíbrios dinâmicos no sistema de produção;
- **Perda rápida de produtividade (Classe 5):** queda repentina de vazão de produção, possivelmente associada a restrições na formação ou variações de pressão de fundo;
- **Restrição súbita no PCK (Classe 6):** obstrução repentina na válvula choke de produção, reduzindo a vazão e alterando o regime de escoamento;
- **Incrustação no PCK (Classe 7):** formação progressiva de depósitos sólidos na válvula choke, afetando o controle e estabilidade do fluxo;
- **Hidrato na linha de produção (Classe 8):** formação de hidratos gasosos na linha principal, provocando bloqueios parciais ou totais;
- **Hidrato na linha de serviço (Classe 9):** obstrução por hidratos na linha auxiliar, afetando o equilíbrio térmico e a segurança operacional.


2.3 Análise Exploratória de Dados

A análise exploratória de dados é uma etapa fundamental para compreender os padrões e características dos dados do 3W Dataset 2.0.0. Nesta seção, são analisados o comportamento dinâmico das séries temporais, a variabilidade entre eventos, a distribuição das classes e a disponibilidade dos sensores, servindo de base para as decisões metodológicas adotadas ao longo do trabalho.

2.3.1 Comportamento Dinâmico das Séries Temporais

Para que um sistema de diagnóstico preventivo seja capaz de detectar anomalias, é imprescindível estabelecer o padrão de normalidade do poço. A Figura 2.2 apresenta o comportamento de um poço em operação normal (Classe 0), em que o fundo em cinza indica o período em que as amostras não foram rotuladas com o estado de operação e o fundo verde indica amostras classificadas com estado normal.


Figura 2.2 – Exemplo de dinâmica para instância da Classe 0 (Operação Normal).



Observa-se que, em regime permanente e sem distúrbios de escoamento, variáveis críticas como a pressão de fundo (P-PDG) e a pressão na árvore de natal molhada (P-TPT) mantêm-se em patamares estáveis, i.e., com baixa amplitude em torno da média do sinal. As pequenas flutuações visíveis correspondem ao ruído natural de medição e à dinâmica dos fluidos em condições nominais, as quais o modelo de detecção deve aprender a ignorar para evitar alarmes falsos.


Quando um evento indesejado ocorre, a perturbação propaga-se pelo sistema, alterando o equilíbrio termodinâmico do escoamento. A Figura 2.3 ilustra um evento de falha por hidrato na linha de produção, destacando as zonas de operação normal (verde), transiente operacional (amarelo) e o estabelecimento do regime ativo de falha (vermelho).

Figura 2.3 – Exemplo da dinâmica da falha por Hidrato na Linha de Produção



A Figura 2.4 ilustra a interdependência entre as variáveis do poço. Uma restrição na válvula choke reflete-se quase imediatamente nas leituras de pressão e temperatura em diferentes pontos do sistema, alterando o padrão de vários sensores ao mesmo tempo. Esse comportamento mostra que as falhas raramente se manifestam em uma única variável, o que reforça a importância de analisar o conjunto de sensores de forma multivariada.

Figura 2.4 – Exemplo da dinâmica da falha por Restrição súbita no PCK



Um dos maiores desafios na automação do diagnóstico de falhas na indústria de óleo e gás é a variabilidade intra-classe ([Vargas et al., 2019](#); [Fawaz et al., 2019](#)). O mesmo fenômeno físico pode apresentar assinaturas temporais significativamente distintas dependendo da geometria do poço, do histórico de produção e das propriedades do fluido. As Figuras 2.5 e 2.6 comparam duas instâncias distintas pertencentes à mesma classe de falha.

Figura 2.5 – Exemplo 1 da dinâmica da falha por Hidrato na Linha de Serviço





Figura 2.6 – Exemplo 2 da dinâmica da falha por Hidrato na Linha de Serviço




Apesar de representarem o mesmo problema raiz, nota-se que a magnitude das varia-

ções, o tempo até a estabilização da falha e os valores de base de cada poço são completamente diferentes. Esse comportamento heterogêneo evidencia a necessidade de modelos de aprendizado de máquina capazes de capturar padrões complexos em dados altamente ruidosos, sem depender de limiares fixos ou regras estáticas, motivando as abordagens investigadas neste trabalho.

2.3.2 Distribuição e Disponibilidade dos Dados


A duração das instâncias varia de forma expressiva entre classes, conforme ilustrado na Figura 2.7. A classe 7 (Incrustação no PCK) apresenta a maior mediana, com instâncias próximas a dois dias de duração. Nota-se também diferenças marcantes no espalhamento: algumas classes, como a 4 (Instabilidade de Fluxo), têm distribuições muito concentradas, indicando que praticamente todas as instâncias têm duração similar; outras, como a classe 8 (Hidrato na Linha de Produção), apresentam grande variação, com instâncias que vão de poucas horas a vários dias. Essa assimetria amplifica o desequilíbrio entre classes: eventos raros contribuem com proporcionalmente menos dados de treinamento, somando-se à menor quantidade de instâncias disponíveis.

Figura 2.7 – Distribuição da duração das instâncias por classe de falha.




A Figura 2.8 quantifica o percentual de dados faltantes por sensor e classe. Sensores de estado de válvula, pressão anular e bomba de serviço apresentam NaN acima de 80% na maioria das classes, tornando-os pouco informativos para a modelagem direta.

Figura 2.8 – Percentual de dados faltantes por sensor e classe de falha.



A Figura 2.9 consolida a disponibilidade de cada sensor: a fração de todos os segundos do dataset em que aquele sensor possui leitura válida. Sensores com baixa cobertura fornecem poucos dados ao longo do dataset, o que os torna pouco informativos para uso em modelos de classificação.

Figura 2.9 – Fração de amostras com leitura válida por sensor no 3W Dataset 2.0.0.



A Tabela 2.6 detalha a distribuição dos 1.119 episódios reais entre os 40 poços físicos identificados no dataset. A distribuição é altamente assimétrica: quatro poços (WELL-00001, WELL-00002, WELL-00005 e WELL-00006) concentram 53% de todas as instâncias reais. Em classes específicas, essa concentração é ainda mais pronunciada; a Instabilidade de Fluxo (classe 4) tem 57% de seus episódios em dois poços, e a Incrustação no PCK (classe 7) concentra mais da metade em um único poço (WELL-00024). Isso representa uma limitação intrínseca do dataset, pois um modelo pode acabar aprendendo padrões característicos de poços específicos em vez de padrões genuínos do tipo de falha, comprometendo sua capacidade de identificar o evento em poços não vistos durante o treinamento.


Tabela 2.6 – Distribuição de episódios reais por poço físico e classe de falha.

Poço	0	1	2	3	4	5	6	7	8	9	Total
WELL-00001	93	1	-	1	36	-	-	1	-	-	132
WELL-00002	209	1	1	-	112	-	3	-	-	-	326
WELL-00003	26	-	3	-	-	-	-	-	-	-	29
WELL-00004	12	-	-	-	43	-	3	-	-	-	58
WELL-00005	81	-	-	-	38	-	-	-	-	-	119
WELL-00006	113	2	-	-	-	-	-	2	-	-	117
WELL-00007	2	-	-	-	10	-	-	-	-	-	12
WELL-00008	57	-	-	-	-	-	-	-	-	-	57
WELL-00009	-	-	1	-	-	-	-	-	-	-	1
WELL-00010	-	-	1	-	83	-	-	-	-	5	89
WELL-00011	-	-	13	-	-	-	-	-	-	-	13
WELL-00012	-	-	2	-	-	-	-	-	-	-	2
WELL-00013	-	-	1	-	-	-	-	-	-	-	1
WELL-00014	-	-	-	31	21	-	-	-	-	3	55
WELL-00015	-	-	-	-	-	1	-	-	-	1	2
WELL-00016	-	-	-	-	-	4	-	-	-	3	7
WELL-00019	1	-	-	-	-	-	-	-	4	-	5
WELL-00020	-	-	-	-	-	6	-	-	-	1	7
WELL-00021	-	-	-	-	-	-	-	2	-	-	2
WELL-00022	-	-	-	-	-	-	-	8	-	-	8
WELL-00023	-	-	-	-	-	-	-	4	-	-	4
WELL-00024	-	-	-	-	-	-	-	19	-	-	19
WELL-00025	-	-	-	-	-	-	-	-	1	-	1
WELL-00026	-	-	-	-	-	-	-	-	3	-	3
WELL-00027	-	-	-	-	-	-	-	-	1	-	1
WELL-00028	-	-	-	-	-	-	-	-	1	-	1
WELL-00029	-	-	-	-	-	-	-	-	1	-	1
WELL-00030	-	-	-	-	-	-	-	-	1	-	1
WELL-00031	-	-	-	-	-	-	-	-	1	-	1
WELL-00032	-	-	-	-	-	-	-	-	1	-	1
WELL-00033	-	-	-	-	-	-	-	-	-	6	6
WELL-00034	-	-	-	-	-	-	-	-	-	6	6
WELL-00035	-	-	-	-	-	-	-	-	-	6	6
WELL-00036	-	-	-	-	-	-	-	-	-	3	3
WELL-00037	-	-	-	-	-	-	-	-	-	4	4
WELL-00038	-	-	-	-	-	-	-	-	-	2	2
WELL-00039	-	-	-	-	-	-	-	-	-	2	2
WELL-00040	-	-	-	-	-	-	-	-	-	1	1
WELL-00041	-	-	-	-	-	-	-	-	-	9	9
WELL-00042	-	-	-	-	-	-	-	-	-	5	5
Total	594	4	22	32	343	11	6	36	14	57	1119

2.3.3 Correlações Cruzadas


A Figura 2.10 apresenta a cobertura por par de sensores, ou seja, o percentual do dataset em que ambos possuem leitura simultânea. Pares com baixa cobertura geram correlações menos confiáveis e indicam quais combinações raramente coexistem no mesmo instante de medição.

Figura 2.10 – Cobertura por par de sensores no 3W Dataset.



A Figura 2.11 apresenta a matriz de correlação de Pearson (James *et al.*, 2013) entre os sensores do dataset. Para cada par, são utilizadas apenas as amostras em que ambos possuem leitura válida simultaneamente. Pares com menos de 500 amostras em comum ficam em branco.


Figura 2.11 – Matriz de correlação de Pearson entre os sensores contínuos do 3W Dataset.



2.3.4 Pairplot dos Sensores Principais

A Figura 2.12 apresenta o pairplot de oito sensores do dataset, com 500 amostras por classe de falha. A diagonal mostra o histograma de cada sensor por classe e as demais células exibem a dispersão entre pares de sensores. É possível observar uma certa separabilidade entre as distribuições das classes para cada sensor, o que sugere que os modelos de classificação poderão explorar esses padrões para distinguir os tipos de falha.

Figura 2.12 – Pairplot dos sensores principais do 3W Dataset, com 500 amostras por classe de falha.




2.3.5 Análise de Componentes Principais

A Análise de Componentes Principais (*Principal Component Analysis* - PCA) é uma técnica estatística que transforma o conjunto original de variáveis em novas combinações lineares, chamadas de componentes principais, ordenadas pela quantidade de variação que cada uma captura nos dados (James *et al.*, 2013). Aplicada sobre os 13 sensores contínuos com cobertura superior a 10% no dataset (ver Figura 2.9), após normalização por instância, o PCA permite identificar quais padrões dominam a variabilidade do sistema e quais sensores carregam mais informação.

A Figura 2.13 apresenta a variância explicada por cada componente. Poucas componentes já acumulam mais de 80% da variância total, indicando que os sensores do dataset são altamente correlacionados entre si. Esse resultado é esperado em sistemas de produção

offshore: perturbações no escoamento se propagam simultaneamente por vários pontos do poço, fazendo com que múltiplos sensores de pressão respondam de forma coordenada ao mesmo evento.

Figura 2.13 – Variância explicada por componente principal - sensores contínuos do 3W Dataset.




A Figura 2.14 detalha os *loadings* de cada sensor nas componentes principais, isto é, o quanto cada variável contribui para cada eixo de variação encontrado pelo PCA. A primeira componente (PC1) apresenta *loadings* positivos tanto para os sensores de pressão quanto para os de temperatura, indicando que ambos os grupos se movem de forma coordenada: quando o nível de pressão sobe ao longo do sistema, as temperaturas tendem a acompanhar, refletindo o estado geral de produção do poço.

A segunda componente (PC2) captura uma relação de sentido oposto entre os dois grupos, com *loadings* positivos para pressão e negativos para temperatura (ou vice-versa), revelando uma fonte de variação em que aumento de pressão coincide com redução de temperatura. O QGL apresenta *loadings* relevantes nas componentes de ordem intermediária, indicando que a injeção de gás lift introduz uma fonte de variação relativamente independente das condições passivas de pressão e temperatura.


Os sensores de abertura de válvula (ABER-CKP e ABER-CKGL), por sua vez, apresentam *loadings* de baixa magnitude em praticamente todas as componentes, sugerindo que essas variáveis de controle permanecem estáveis durante a maior parte do tempo de operação e contribuem pouco para os padrões globais capturados pelo PCA.

Figura 2.14 – *Loadings* das componentes principais - contribuição de cada sensor por componente.



O ranking de importância global, apresentado na Figura 2.15, sintetiza a contribuição ponderada de cada sensor ao longo de todas as componentes. Os sensores mais informativos são o P-MON-CKP e o P-TPT, seguidos de perto pelos sensores de temperatura T-TPT e T-JUS-CKP. Esse resultado indica que a região entre a árvore de natal molhada e o choke de produção concentra grande parte da informação sobre o estado do poço.

Figura 2.15 – Ranking de importância global dos sensores por PCA.



Esses resultados orientam as decisões metodológicas adotadas ao longo deste trabalho, desde a seleção de sensores até as estratégias de pré-processamento e engenharia de *features*, discutidas no Capítulo 4.

2.4 Desafios e Características Intrínsecas


Haja vista que a maior parte dos dados advém de processos industriais reais, a base apresenta diversas dificuldades que tornam sua análise desafiadora. Entre as principais estão:

- **Variáveis ausentes:** 65,9% das variáveis apresentam lacunas devido a falhas de sensores ou comunicação;
- **Variáveis congeladas:** cerca de 9,8% das variáveis mantêm valor constante por longos períodos, dificultando a detecção de padrões dinâmicos;
- **Distribuição desbalanceada:** a maior parte das instâncias pertence à classe 0 (operação normal), enquanto as falhas são raras;
- **Duração variável dos eventos:** janelas de falha variam de minutos a horas;

- **Imprecisão nos rótulos (*label noise*):** os rótulos foram atribuídos retroativamente por especialistas com base na inspeção visual das séries completas, o que introduz imprecisão temporal nos instantes de início dos eventos;
- **Rotulagem incompleta em instâncias reais:** 43 das 57 instâncias reais de Hidrato na Linha de Serviço (Classe 9) não possuem rótulos de transiente nem de falha ativa, contribuindo apenas com amostras de operação normal para a tarefa de classificação.

Essas características exigem o uso de técnicas avançadas de pré-processamento, imputação e aprendizado robusto, capazes de lidar com ruído, desbalanceamento e dependências temporais complexas. A imprecisão nos rótulos merece atenção especial por afetar diretamente a avaliação dos modelos. A Figura 2.16, que retoma a instância já apresentada na Figura 2.4, ilustra esse problema para um poço real da Classe 6 (Restrição Rápida no PCK): os sensores ABER-CKP, P-MON-CKP e P-TPT apresentam mudanças consistentes ainda no período rotulado como operação normal, indicando que a anomalia começa a se desenvolver antes do rótulo oficial de transiente.

Figura 2.16 – Imprecisão de rotulagem em instância real da Classe 6 (Restrição Rápida no PCK).



Confusões entre os estados normal e transiente nos resultados dos modelos não representam necessariamente erros reais de classificação, mas podem refletir essa imprecisão inerente à rotulagem manual.


3 Fundamentação Teórica

Este capítulo apresenta os conceitos teóricos que fundamentam as escolhas metodológicas deste trabalho. Inicialmente, descreve-se o modelo base de árvores de decisão, cuja limitação de alta variância motiva o uso de métodos *ensemble*. Em seguida, apresentam-se os dois paradigmas de *ensemble* utilizados: *bagging* (base do Random Forest) e *boosting* sequencial (base do XGBoost). Como abordagens de aprendizado profundo, apresentam-se a rede convolucional 1D na arquitetura FCN e a arquitetura CNN-LSTM, que aprendem representações diretamente da série temporal bruta, dispensando a extração manual de *features*. Por fim, discute-se a estratégia de validação cruzada, com ênfase no *GroupKFold* e na validação cruzada aninhada, que garantem avaliações sem vazamento de informação entre poços.

3.1 Árvores de Decisão

Uma árvore de decisão (Breiman, 2001) é um modelo de aprendizado supervisionado que particiona recursivamente o espaço de features em regiões cada vez mais homogêneas em relação à variável alvo. A estrutura consiste em nós de decisão (que aplicam uma condição sobre uma feature), nós folha (que armazenam a predição final) e arestas (que direcionam o fluxo conforme o resultado da condição), como ilustrado na Figura 3.1. Para classificação multiclasse, a predição de uma folha é a classe majoritária das amostras de treinamento que chegam àquela folha.

Figura 3.1 – Exemplo de estrutura de uma árvore de decisão com nós de decisão, arestas e nós folha.



3.1.1 Critério de Divisão

A escolha de qual feature e qual limiar usar em cada divisão é guiada por um critério de impureza, como o Índice de Gini (Breiman *et al.*, 1984). Esse índice, utilizado neste trabalho, mede a probabilidade de uma amostra escolhida aleatoriamente ser classificada incorretamente se rotulada conforme a distribuição de classes do nó:

$$\text{Gini}(t) = 1 - \sum_{c=1}^C p(c | t)^2 \quad (3.1)$$

onde $p(c | t)$ é a fração de amostras da classe c no nó t e C é o número de classes. Um nó puro ($\text{Gini} = 0$) contém amostras de uma única classe; um nó maximamente impuro ($\text{Gini} = 1 - 1/C$) tem distribuição uniforme. A melhor divisão em cada nó é aquela que maximiza a redução de impureza (ganho de Gini):

$$\Delta\text{Gini}(t_{\text{pai}}) = \text{Gini}(t_{\text{pai}}) - \sum_{f \in \{E, D\}} \frac{|t_f|}{|t_{\text{pai}}|} \text{Gini}(t_f) \quad (3.2)$$

onde $f \in \{E, D\}$ indexa os nós filhos esquerdo (E) e direito (D) resultantes da divisão, t_f é o nó filho correspondente e $|t_f|$ é o número de amostras nesse nó.

3.1.2 Overfitting e Alta Variância

Árvores sem restrição de profundidade tendem a se ajustar perfeitamente ao conjunto de treino (*overfitting*), criando divisões que capturam ruídos em vez de padrões reais. O resultado é alta variância: pequenas perturbações nos dados de treino geram árvores radicalmente diferentes. Essa limitação é a principal motivação para os métodos *ensemble* apresentados nas seções seguintes.

3.2 Bagging e Random Forest

3.2.1 Amostragem Bootstrap e Bagging


A amostragem bootstrap sorteia, com reposição, N observações de um conjunto de treino de N amostras. Por ser feito com reposição, a mesma observação pode ser sorteada mais de uma vez; em média, cerca de 63% das observações únicas do conjunto original aparecem em cada amostra bootstrap (Efron, 1979).

O Bagging (*Bootstrap Aggregating*) (Breiman, 2001) treina B modelos independentes, cada um sobre uma amostra bootstrap distinta, e combina as predições por votação majoritária (classificação). O efeito principal é a redução de variância sem aumento substancial do viés: árvores treinadas em amostras diferentes capturam padrões ligeiramente distintos e, ao combinar seus votos, os erros específicos de cada árvore se cancelam.

3.2.2 Random Forest

O *Random Forest* (Breiman, 2001) estende o Bagging com uma segunda fonte de aleatorização: em cada nó de cada árvore, apenas um subconjunto aleatório de m features é considerado para a divisão (em vez de todas as p features), conforme ilustrado na Figura 3.2. Para classificação, o valor padrão é $m = \lfloor \sqrt{p} \rfloor$ (Breiman, 2001). No contexto deste trabalho, $p = 88$ features, portanto $m = 9$.

Figura 3.2 – Estrutura do Random Forest.



Essa restrição reduz a correlação entre as árvores do *ensemble*: se uma feature muito informativa domina as divisões, árvores sem aleatorização tenderiam a ser semelhantes entre si, limitando o benefício do Bagging. Com a seleção aleatória de features, cada árvore explora regiões diferentes do espaço de features, aumentando a diversidade e, consequentemente, a redução de variância do conjunto.

A importância de uma feature j no Random Forest é calculada pelo *Mean Decrease in Impurity* (MDI): para cada nó t de cada árvore que usa a feature j , acumula-se a redução ponderada de impureza:

$$\text{MDI}(j) = \frac{1}{B} \sum_{b=1}^B \sum_{t \in T_b: j_t=j} \frac{|t|}{N} \Delta \text{Gini}(t) \quad (3.3)$$

onde T_b é o conjunto de nós internos da b -ésima árvore, j_t é a feature utilizada na divisão do nó t , $\Delta \text{Gini}(t)$ é o ganho de impureza calculado conforme a Equação 3.2, $|t|$ é o número de amostras no nó t e N é o total de amostras de treino.

3.3 Gradient Boosting e XGBoost

3.3.1 Boosting Sequencial

Enquanto o Bagging combina modelos independentes treinados em paralelo, o Boosting conecta M modelos fracos (tipicamente árvores rasas) sequencialmente: o primeiro modelo treina com os dados de entrada e cada modelo subsequente é treinado sobre os resíduos do modelo anterior. O modelo final é uma soma ponderada desses M modelos:

$$F_M(x) = F_0(x) + \sum_{m=1}^M \eta h_m(x) \quad (3.4)$$

onde $F_0(x)$ é uma predição inicial (geralmente a média ou probabilidade a priori), $h_m(x)$ é o m -ésimo modelo fraco e $\eta \in (0, 1]$ é a taxa de aprendizado (*shrinkage*), que controla a contribuição de cada modelo e atua como regularizador.

O *Gradient Boosting* interpreta o Boosting como uma descida de gradiente no espaço funcional: cada h_m é ajustado para aproximar o gradiente negativo da função de perda $-\partial L / \partial F_{m-1}(x_i)$. Para classificação multiclasse, utiliza-se a perda de entropia cruzada com função de ativação *softmax*.


3.3.2 XGBoost

O XGBoost (*eXtreme Gradient Boosting*) (Chen; Guestrin, 2016) aprimora o Gradient Boosting com regularização explícita e otimizações computacionais, conforme ilustrado na Figura 3.3. A função objetivo de cada iteração m tem dois termos:

$$\mathcal{L}^{(m)} = \sum_{i=1}^N \ell(y_i, \hat{y}_i^{(m-1)} + h_m(x_i)) + \Omega(h_m) \quad (3.5)$$

onde $\ell(y_i, \hat{y}_i)$ é a função de perda que compara o rótulo verdadeiro y_i com a predição acumulada $\hat{y}_i^{(m-1)} + h_m(x_i)$, e $\Omega(h_m)$ é o termo de regularização. O primeiro termo mede o erro de predição acumulado sobre todas as amostras; o segundo penaliza árvores com muitas folhas ou com pesos muito grandes, controlando a complexidade do modelo e evitando *overfitting*. A função admite solução exata para os pesos ótimos de cada folha, o que torna cada iteração eficiente.

Figura 3.3 – Arquitetura sequencial do XGBoost




No caso de *features* numéricas, pode-se quantizar seus valores antes de procurar a melhor divisão em cada nó. Isso reduz o número de candidatos de divisão avaliados e permite treinar sobre conjuntos com centenas de milhares de amostras, como os deste trabalho.

3.4 Redes Convolucionais 1D

As redes convolucionais 1D (CNN-1D) constituem uma abordagem alternativa aos modelos baseados em *features* para classificação de séries temporais. Em vez de extrair estatísticas manualmente, a CNN-1D aprende automaticamente representações relevantes diretamente da série temporal bruta X_t , $1 \leq t \leq n$, durante o treinamento, aplicando filtros deslizantes sobre a dimensão temporal, como ilustrado na Figura 3.4.

Figura 3.4 – Arquitetura típica de rede convolucional 1D.



3.4.1 Convolução 1D

Uma camada convolucional 1D aplica F filtros deslizantes de comprimento k sobre uma série temporal de entrada $\mathbf{x} \in \mathbb{R}^{T \times S}$, onde T é o número de amostras temporais e S é o número de canais (sensores). Para o f -ésimo filtro com pesos $\mathbf{w}_f \in \mathbb{R}^{k \times S}$, a saída no instante t é:

$$z_f(t) = \text{ReLU} \left(\sum_{s=1}^S \sum_{\tau=0}^{k-1} w_{f,\tau,s} x(t + \tau, s) + b_f \right) \quad (3.6)$$

onde b_f é o viés e $\text{ReLU}(z) = \max(0, z)$ (Goodfellow; Bengio; Courville, 2016) é a função de ativação que introduz não-linearidade.

Cada filtro atua como um detector de padrão local de comprimento k . Filtros com k grande detectam padrões de larga escala temporal (tendências, variações lentas), enquanto filtros com k pequeno identificam transições abruptas e padrões locais. Ao empilhar camadas com *kernels* de tamanhos decrescentes, a rede captura padrões em múltiplas escalas temporais.

3.4.2 Normalização em Lote

Após cada camada convolucional, aplica-se *Batch Normalization* (BN) (Ioffe; Szegedy, 2015): para cada partição (lote) dos dados de treino, as ativações são normalizadas para média zero e desvio padrão unitário, e então reescaladas por parâmetros aprendíveis γ e β :

$$\hat{z} = \frac{z - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}, \quad \tilde{z} = \gamma \hat{z} + \beta \quad (3.7)$$

onde μ_B e σ_B^2 são a média e a variância do mini-lote, e ε é uma constante pequena ($\varepsilon \ll 1$) adicionada para estabilidade numérica, evitando divisão por zero. A normalização evita que as ativações cresçam descontroladamente ao longo das camadas, permitindo taxas de aprendizado maiores e acelerando a convergência.

3.4.3 Global Average Pooling e Arquitetura FCN


Após a última camada convolucional, um tensor de dimensão $(T \times F)$, com T instantes temporais e F filtros, precisa ser reduzido a um vetor para a camada de classificação final. A operação *Global Average Pooling* (GAP) 1D calcula a média temporal de cada canal:

$$\text{GAP}(f) = \frac{1}{T} \sum_{t=1}^T z_f(t) \quad (3.8)$$

O resultado do GAP reduz a dimensão da entrada de $T \times F$ para F , produzindo um vetor independente de T , o que reduz drasticamente o número de parâmetros e a tendência ao *overfitting*.

A arquitetura FCN (*Fully Convolutional Network*) de Wang, Yan e Oates (2017) combina esses elementos em três blocos consecutivos com kernels decrescentes, seguidos de GAP e uma camada densa de classificação, conforme mostrado na Figura 3.5:

Figura 3.5 – Arquitetura Fully Convolutional Network (FCN).



A FCN é estabelecida como *baseline* forte para classificação de séries temporais, apresentando desempenho competitivo em mais de 80 conjuntos de dados do repositório *UCR Time Series Classification Archive* (Fawaz et al., 2019), sem necessidade de extração manual de *features*.

3.5 Redes Recorrentes e LSTM

3.5.1 Redes Neurais Recorrentes e o Gradiente Desvanecente

Redes neurais do tipo *feedforward* processam cada entrada de forma independente: a predição para o instante t depende exclusivamente de $\mathbf{x}_t$, sem acesso a informações dos instantes anteriores. Para dados estáticos, isso é suficiente. Para dados sequenciais, como séries temporais de sensores, esse mecanismo falha: a ausência de contexto temporal impede que o modelo detecte dependências entre instantes distantes, como a progressão gradual de pressão que precede um evento de hidrato.

As redes neurais recorrentes (RNN) (Goodfellow; Bengio; Courville, 2016) superam essa limitação ao introduzir um estado oculto $\mathbf{h}_t$ que resume a informação acumulada dos passos temporais anteriores. Em vez de processar cada instante de forma isolada, a RNN mantém uma memória implícita que é atualizada a cada novo passo a partir da entrada atual e do contexto já acumulado. No passo t , a atualização do estado oculto é:

$$\mathbf{h}_t = \tanh(\mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{W}_x \mathbf{x}_t + \mathbf{b}) \quad (3.9)$$

onde $\mathbf{x}_t$ é a entrada no instante t e $\mathbf{W}_h$, $\mathbf{W}_x$ são matrizes de peso aprendidas durante o treinamento. Embora teoricamente capaz de modelar dependências de longo prazo, na prática a RNN sofre com o gradiente desvanecente (Bengio; Simard; Frasconi, 1994): ao retropropagar o erro por muitos passos temporais, o gradiente é multiplicado repetidamente pela matriz $\mathbf{W}_h$, fazendo seu valor decair exponencialmente.

3.5.2 Long Short-Term Memory (LSTM)

A *Long Short-Term Memory* (LSTM) (Hochreiter; Schmidhuber, 1997) resolve o problema de *vanishing gradient* por meio de um mecanismo de *portas* que controla seletivamente quais informações são retidas, adicionadas ou descartadas a cada passo. A célula LSTM mantém dois vetores de estado: o estado de célula $\mathbf{c}_t$, que representa a memória de longo prazo, e o estado oculto $\mathbf{h}_t$, que é a saída do passo atual.


A cada passo t , três portas regulam o fluxo de informação:

- **Porta de esquecimento ($\mathbf{f}_t$):** decide qual fração de $\mathbf{c}_{t-1}$ deve ser descartada. Saída próxima de zero apaga a memória; próxima de um a preserva integralmente;
- **Porta de entrada ($\mathbf{i}_t$):** controla quanto do candidato $\tilde{\mathbf{c}}_t$ é incorporado ao estado de célula;
- **Porta de saída ($\mathbf{o}_t$):** determina qual parte de $\mathbf{c}_t$ é exposta como estado oculto $\mathbf{h}_t$.

A Figura 3.6 ilustra o fluxo de informação dentro da célula. As entradas $\mathbf{h}_{t-1}$ e $\mathbf{x}_t$ chegam juntas e alimentam as três portas em paralelo. A porta de esquecimento filtra $\mathbf{c}_{t-1}$

pelo fator $\mathbf{f}_t$, descartando o que não é mais relevante. Em seguida, a porta de entrada adiciona novas informações ao estado de célula, somando $\mathbf{i}_t \odot \tilde{\mathbf{c}}_t$ ao resultado anterior. Por fim, a porta de saída lê o estado de célula atualizado, aplica $\tanh$ para reescalar os valores e usa $\mathbf{o}_t$ para decidir o que será exposto como $\mathbf{h}_t$.

Figura 3.6 – Estrutura de uma célula LSTM.



A propriedade fundamental que distingue a LSTM das RNN simples está na atualização do estado de célula:

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (3.10)$$

onde $\odot$ denota o produto elemento a elemento. Nas RNN simples, o estado oculto é propagado por multiplicações repetidas da mesma matriz de pesos, o que faz o gradiente decair rapidamente ao longo do tempo. Na LSTM, o estado de célula é atualizado por adição: quando $\mathbf{f}_t \approx \mathbf{1}$, a informação de $\mathbf{c}_{t-1}$ flui intacta por qualquer número de passos, evitando o gradiente desvanecente. As três portas aplicam, cada uma, uma transformação sigmoide $\sigma(z) = 1/(1+e^{-z})$ (Goodfellow; Bengio; Courville, 2016) sobre $[\mathbf{h}_{t-1}; \mathbf{x}_t]$, com pesos próprios aprendidos durante o treinamento.


3.5.3 Arquitetura CNN-LSTM

A arquitetura CNN-LSTM combina blocos convolucionais com unidades recorrentes, unindo a capacidade das CNNs de extrair padrões locais com a memória sequencial das LSTMs (Fawaz *et al.*, 2019). As camadas convolucionais atuam como extratoras automáticas de features sobre a série temporal, comprimindo a sequência em representações de menor dimensão que preservam as características dinâmicas relevantes. A camada LSTM subse-

quente processa essa sequência comprimida, capturando dependências temporais de longo prazo entre os padrões extraídos.

Neste trabalho, a arquitetura, ilustrada na Figura 3.7, consiste em dois blocos Conv1D com *MaxPooling* que reduzem a dimensão temporal e extraem representações locais dos sinais dos sensores. A sequência comprimida é processada por uma camada LSTM, cuja saída no último passo $\mathbf{h}_T$ passa por uma camada de *Dropout* (Srivastava *et al.*, 2014) e, em seguida, por uma camada densa com ativação *softmax* (Goodfellow; Bengio; Courville, 2016). O *Dropout* desativa aleatoriamente uma fração das unidades durante o treinamento para reduzir o *overfitting*; a ativação *softmax*, dada por $\text{softmax}(\mathbf{z})_c = e^{z_c} / \sum_{j=1}^C e^{z_j}$, converte os logits em probabilidades por classe.

Figura 3.7 – Arquitetura CNN-LSTM: blocos convolucionais com MaxPooling comprimem a sequência temporal, seguidos de camada LSTM, Dropout e classificação softmax.




3.6 Validação Cruzada e GroupKFold

3.6.1 Validação Cruzada k-Fold

A validação cruzada k-fold (James *et al.*, 2013) é uma técnica de estimação de desempenho e ajuste de hiperparâmetros amplamente utilizada em problemas com grande volume de dados. O conjunto de dados é dividido em K subconjuntos (*folds*) de tamanho aproximadamente igual, conforme ilustrado na Figura 3.8. Em cada iteração k , o k -ésimo fold é usado como conjunto de teste e os $K - 1$ folds restantes como treino. O score final é a média dos K scores:

$$\bar{S} = \frac{1}{K} \sum_{k=1}^K S_k, \quad \sigma_S = \sqrt{\frac{1}{K-1} \sum_{k=1}^K (S_k - \bar{S})^2} \quad (3.11)$$

Figura 3.8 – Ilustração da validação cruzada com 5 folds.



O desvio padrão σ_S quantifica a variabilidade do desempenho entre os folds e indica se o modelo é sensível à escolha dos dados de treino.

3.6.2 Data Leakage em Séries Temporais

Quando os dados são séries temporais de múltiplas instâncias (poços), a divisão aleatória padrão do k-fold pode causar *data leakage*: para um mesmo poço, uma janela na partição de teste pode ter sobreposição temporal com janelas que estão na partição de treino. Como janelas sobrepostas do mesmo poço são altamente correlacionadas, o modelo aprende padrões específicos de cada poço em vez de generalizar. O resultado é uma performance artificialmente otimista que não reflete o desempenho em poços novos.

3.6.3 GroupKFold

O GroupKFold agrupa as amostras por um identificador de grupo, garantindo que todas as janelas de uma mesma instância pertençam sempre ao mesmo fold. Neste trabalho, o grupo é definido pelo `instance_id`, identificador único atribuído a cada arquivo de série temporal do 3W Dataset (cada episódio registrado de operação de um poço). Formalmente, para um conjunto de grupos $\mathcal{G} = \{g_1, g_2, \dots, g_G\}$:

$$\forall g \in \mathcal{G} : g \subset \text{Treino}_k \oplus g \subset \text{Teste}_k \quad (3.12)$$


onde $\oplus$ denota o ou-exclusivo, ou seja, nenhuma instância aparece simultaneamente em treino e teste, garantindo que o modelo seja sempre avaliado em episódios não vistos durante o treinamento.

3.6.4 Validação Cruzada Aninhada

A validação cruzada aninhada (*nested CV*) separa a seleção de hiperparâmetros da estimativa de desempenho em dois loops hierárquicos, conforme ilustrado na Figura 3.9:

- **Loop externo** (K_{out} folds): reserva um fold como teste final e passa o restante dos dados ao loop interno;
- **Loop interno** (K_{in} folds): realiza a busca de hiperparâmetros usando apenas os dados de treino do fold externo, sem enxergar o fold de teste.

Figura 3.9 – Estrutura da validação cruzada aninhada com loops externo e interno.



Ao final, cada fold externo produz uma estimativa de desempenho obtida com hiperparâmetros selecionados em dados completamente independentes do teste.

3.7 Filtragem de Sinal

Após a normalização Z-score, os sinais dos sensores são filtrados para atenuar ruídos de instrumentação de alta frequência sem comprometer as tendências dinâmicas relevantes para a detecção de falhas. Este trabalho avalia dois métodos de filtragem distintos: o filtro Gaussiano (Oppenheim; Schafer, 2009), um passa-baixa linear clássico, e o filtro estatístico adaptativo (Gomes, 2022), um passa-baixa não linear que ajusta o grau de suavização à magnitude local da variação do sinal. Seus efeitos sobre o sinal são comparados na Seção 4.7.

3.7.1 Filtro Gaussiano

O filtro Gaussiano (Oppenheim; Schaffer, 2009) é um filtro linear passa-baixa clássico, amplamente utilizado em processamento de sinais para suavização. Seu *kernel* é definido pela função de densidade Gaussiana:

$$g[k] = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{k^2}{2\sigma^2}\right) \quad (3.13)$$

onde σ controla a largura do *kernel* e, portanto, o grau de suavização. O sinal filtrado y é obtido pela convolução discreta do sinal de entrada x com o *kernel* g :

$$y[n] = \sum_k g[k] x[n - k] \quad (3.14)$$

O parâmetro $\sigma = 2,0$ é o desvio padrão do *kernel* gaussiano e define a escala característica da suavização: para séries a 1 Hz, corresponde a 2 segundos. Isso significa que o filtro pondera os vizinhos de cada amostra com pesos que decaem segundo uma curva em sino, concentrando 95% do peso dentro de $\pm 2\sigma = \pm 4$ amostras ao redor de cada ponto.

3.7.2 Filtro Estatístico Adaptativo

O filtro estatístico adaptativo (Gomes, 2022) é um método não linear que ajusta o grau de suavização em função da magnitude local da variação do sinal. A ideia central é distinguir ruído de instrumentação (variações pequenas) de eventos reais (variações abruptas): variações pequenas são suavizadas enquanto variações grandes são preservadas.

O parâmetro de adaptação $\alpha[k]$ é calculado a cada instante k como:

$$\alpha[k] = \operatorname{erf}\left(\frac{|y_O[k-1] - y_I[k]|}{\sqrt{2} \cdot 2\sigma}\right) \quad (3.15)$$

onde $y_I[k]$ é o sinal ruidoso de entrada no instante k , $y_O[k-1]$ é a saída filtrada no passo anterior, σ é o parâmetro de sensibilidade e $\operatorname{erf}(\cdot)$ é a função erro (Abramowitz; Stegun, 1964). O sinal filtrado é então:

$$y_O[k] = (1 - \alpha[k]) y_O[k-1] + \alpha[k] y_I[k] \quad (3.16)$$

Quando $|y_O[k-1] - y_I[k]| \ll \sigma$, tem-se $\alpha[k] \approx 0$ e $y_O[k] \approx y_O[k-1]$: o filtro ignora a variação e mantém a saída anterior. Quando $|y_O[k-1] - y_I[k]| \gg \sigma$, tem-se $\alpha[k] \rightarrow 1$ e $y_O[k] \approx y_I[k]$: o filtro segue o sinal de entrada. Para eliminar o atraso de fase introduzido pelo processamento causal, o filtro é aplicado duas vezes, nos sentidos direto e inverso.

3.8 Métricas de Avaliação

Para problemas de classificação multiclasse com C classes, as métricas de desempenho são definidas por classe a partir da matriz de confusão (James *et al.*, 2013), que registra, para cada par (classe verdadeira, classe predita), o número de amostras correspondente. Para uma classe c , define-se o número de verdadeiros positivos TP_c (amostras da classe c corretamente classificadas), falsos positivos FP_c (amostras de outras classes classificadas como c) e falsos negativos FN_c (amostras da classe c classificadas como outra).

A precisão (James *et al.*, 2013) mede a fração das predições positivas que estão corretas:

$$\text{Precisão}_c = \frac{TP_c}{TP_c + FP_c} \quad (3.17)$$

O recall (sensibilidade) (James *et al.*, 2013) mede a fração das amostras reais da classe que foram detectadas:

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \quad (3.18)$$

O F1-score (James *et al.*, 2013) é a média harmônica entre precisão e recall, penalizando modelos que sacrificam um em favor do outro:

$$F1_c = 2 \cdot \frac{\text{Precisão}_c \cdot \text{Recall}_c}{\text{Precisão}_c + \text{Recall}_c} = \frac{2 TP_c}{2 TP_c + FP_c + FN_c} \quad (3.19)$$

Para comparar modelos em problemas multiclasse com classes desbalanceadas, as métricas por classe são agregadas de duas formas (James *et al.*, 2013). O F1-macro calcula a média aritmética do F1-score sobre as C classes, atribuindo peso igual a cada classe independentemente de seu tamanho:

$$\text{F1-macro} = \frac{1}{C} \sum_{c=1}^C F1_c \quad (3.20)$$

O F1-weighted pondera cada classe pelo número de amostras n_c :

$$\text{F1-weighted} = \sum_{c=1}^C \frac{n_c}{N} F1_c \quad (3.21)$$

onde $N = \sum_c n_c$ é o total de amostras. A acurácia (James *et al.*, 2013) é a fração global de predições corretas:

$$\text{Acurácia} = \frac{\sum_{c=1}^C TP_c}{N} \quad (3.22)$$

4 Metodologia


Este capítulo descreve o pipeline desenvolvido para a classificação do estado operacional de poços de petróleo a partir do 3W Dataset. O objetivo é, dada uma janela de 300 segundos de dados de sensores, determinar em qual dos 17 estados operacionais o poço se encontra (operação normal, evento ativo ou transiente). A metodologia foi estruturada em cinco estágios sequenciais: pré-processamento dos dados, extração de features por janela-deslizante, rotulagem por estado operacional, treinamento e validação de modelos de classificação, e análise de interpretabilidade com SHAP.

Toda a implementação foi desenvolvida em Python 3, utilizando os seguintes pacotes principais: *scikit-learn* (Pedregosa *et al.*, 2011) para os modelos RF e para o pipeline de validação cruzada; *XGBoost* (Chen; Guestrin, 2016) para o modelo de *gradient boosting*; *Keras* com *TensorFlow* como *backend* (Abadi *et al.*, 2016) para as arquiteturas CNN-1D e CNN-LSTM; *NumPy* (Harris *et al.*, 2020) e *SciPy* (Virtanen *et al.*, 2020) para manipulação de dados e filtragem de sinal; e *SHAP* (Lundberg *et al.*, 2020) para a análise de interpretabilidade. Os experimentos foram executados em um computador com processador AMD Ryzen 5 5600X (6 núcleos físicos, 12 *threads*), 16 GB de memória RAM e GPU NVIDIA GeForce RTX 2060 com 6 GB de memória de vídeo, utilizada no treinamento das redes neurais.

4.1 Visão Geral do Pipeline

O fluxo metodológico completo é apresentado na Figura 4.1. O pipeline recebe como entrada os arquivos *Parquet* brutos do 3W Dataset, organizados por classe de falha, e produz como saída modelos treinados, métricas de desempenho e análises de interpretabilidade.

Figura 4.1 – Fluxograma metodológico do pipeline de classificação de estado operacional.



Os cinco estágios do pipeline são:

- i) **Limpeza e Normalização:** leitura em lotes, limpeza de dados ausentes, seleção de sensores e normalização por instância;
- ii) **Janelamento e Rotulagem:** segmentação das séries temporais em janelas deslizantes de 300s e rotulagem de cada janela com base na classe mais frequente;
- iii) **Extração de Features:** cálculo de 11 features estatísticas por sensor para cada janela;
- iv) **Treinamento e Avaliação:** treinamento e comparação de desempenho entre modelos com validação cruzada aninhada e previsões *out-of-fold*;
- v) **Interpretabilidade:** análise SHAP para identificar quais features e sensores mais contribuem para a classificação de cada estado operacional.

4.2 Pré-processamento dos Dados

4.2.1 Leitura em Lotes e Limpeza

O 3W Dataset contém 2.228 instâncias distribuídas em arquivos *Parquet* individuais, totalizando centenas de milhares de registros temporais. Para evitar estouro de memória durante o processamento, os arquivos são lidos em lotes de 30 instâncias (`batch_size = 30`), mantendo o consumo de memória em aproximadamente 500 MB por lote.

Em cada lote, são realizadas as seguintes etapas de limpeza:

- Remoção de colunas em que todas as amostras são NaN, ou seja, sensores completamente indisponíveis;
- *Forward-fill* limitado a 60 amostras consecutivas, reproduzindo o comportamento de sistemas SCADA que mantêm o último valor válido; buracos maiores permanecem como NaN para preservar a causalidade temporal;
- Descarte de instâncias em que mais de 50% das amostras do sensor P-TPT (pressão na árvore de natal molhada) são NaN, por ser o sensor mais informativo para a maioria dos eventos.

4.2.2 Seleção de Sensores

O 3W Dataset disponibiliza até 27 variáveis por instância, que incluem variáveis binárias de estado, rótulos de classe e sensores analógicos contínuos de pressão, temperatura e vazão. Para este trabalho, foram excluídas as variáveis binárias e categóricas, restando apenas os sensores contínuos como candidatos à entrada dos modelos.

Entre os sensores contínuos, a seleção final aplicou três critérios: relevância física para o monitoramento de garantia de escoamento, disponibilidade de dados suficiente no dataset e importância global segundo a análise de componentes principais apresentada na Seção 2.3.5. Os 8 sensores resultantes, listados na Tabela 4.1, cobrem pressão, temperatura e vazão em pontos estratégicos do poço: fundo de poço (PDG), árvore de natal molhada (TPT), choke de produção (CKP) e linha de injeção de gás lift (CKGL).

Tabela 4.1 – Sensores selecionados para o pipeline de classificação, adaptada das Tabelas 2.2 a 2.4.

Código	Descrição	Grandeza
P-PDG	Pressão no sensor de fundo de poço (PDG)	Pressão
T-PDG	Temperatura no sensor de fundo de poço (PDG)	Temperatura
P-TPT	Pressão na árvore de natal molhada	Pressão
T-TPT	Temperatura na árvore de natal molhada	Temperatura
P-MON-CKP	Pressão no manifold a montante do choke de produção	Pressão
T-JUS-CKP	Temperatura a jusante do choke de produção	Temperatura
P-JUS-CKGL	Pressão a jusante do choke de gás lift	Pressão
QGL	Vazão de gás lift injetado	Vazão

4.2.3 Normalização por Instância

Diferentes poços operam em faixas absolutas de pressão e temperatura distintas. Um mesmo nível de pressão pode indicar operação normal em um poço e falha em outro. Para que o modelo aprenda padrões de mudança relativa em vez de níveis absolutos, cada sensor de cada instância é normalizado individualmente pela transformação Z-score (James *et al.*, 2013):

$$z_{i,j} = \frac{x_{i,j} - \mu_j}{\sigma_j} \quad (4.1)$$

onde $x_{i,j}$ é o valor bruto da amostra i do sensor j naquela instância, μ_j é a média e σ_j o desvio padrão calculados sobre toda a instância.

4.2.4 Filtragem de Sinal

Após a normalização, os sinais são filtrados para atenuar ruídos de instrumentação de alta frequência sem comprometer as tendências dinâmicas relevantes para a detecção de falhas. Os fundamentos matemáticos dos dois métodos avaliados são apresentados na Seção 3.7.

O filtro Gaussiano é adotado como padrão com $\sigma = 2,0$. Como o 3W Dataset é amostrado a 1 Hz, esse valor corresponde a uma suavização efetiva de aproximadamente 10 segundos ($\pm 2\sigma$), suficiente para suprimir oscilações espúrias de instrumentação sem apagar transições de falha que se desenvolvem ao longo de minutos.

O filtro estatístico adaptativo (Gomes, 2022) utiliza $\sigma = 0,5$. Como os sinais já foram normalizados pelo Z-score, variações de amplitude inferior a 0,5 desvios-padrão são tratadas como ruído de instrumentação e atenuadas; variações acima desse limiar são interpretadas

como tendência real do sinal e preservadas. Esse valor atua, portanto, como fronteira entre ruído e informação no espaço normalizado.

4.3 Janelamento Deslizante e Extração de Features

4.3.1 Segmentação por Janela Deslizante

As séries temporais de cada instância são segmentadas em janelas deslizantes de tamanho fixo $T = 300$ amostras (300 s para séries a 1 Hz) e passo $\Delta t = 150$ amostras (50% de sobreposição). Janelas em que 100% das amostras de todos os sensores são NaN são descartadas. Ao final do processo, o conjunto de dados contém 449.397 janelas geradas a partir das 1.409 instâncias.

4.3.2 Features Extraídas

Para cada janela e cada um dos 8 sensores, são calculadas 11 estatísticas resumo, totalizando $8 \times 11 = 88$ features por janela. As estatísticas estão descritas na Tabela 4.2.

Tabela 4.2 – Estatísticas extraídas por sensor em cada janela deslizante (88 features no total).

#	Feature	Descrição
1	mean	Média aritmética das amostras da janela
2	std	Desvio padrão das amostras
3	min	Valor mínimo
4	max	Valor máximo
5	median	Mediana
6	iqr	Amplitude interquartil ($Q3 - Q1$)
7	skewness	Assimetria da distribuição amostral
8	kurtosis	Curtose da distribuição amostral
9	diff1_std	Desvio padrão da 1ª derivada numérica (velocidade de variação)
10	diff2_std	Desvio padrão da 2ª derivada numérica (aceleração de variação)
11	max_zscore	Máximo z-score interno da janela (intensidade do maior pico)

As features `diff1_std` e `diff2_std` capturam a dinâmica da série (quão rapidamente e com qual aceleração o sinal está variando), enquanto `max_zscore` preserva os picos de transiente como informação em vez de descartá-los. Valores NaN remanescentes nas *features* são imputados pela mediana de cada instância individual, calculada exclusivamente sobre

as janelas daquela instância, evitando que informações de instâncias do conjunto de teste contaminem o processo de imputação.

4.4 Rotulagem de Janelas

Cada janela recebe um único rótulo correspondente ao estado operacional dominante naquele intervalo. O rótulo é calculado como a moda dos valores da coluna *class* nas amostras da janela:

$$y_j = \text{moda}(\{c_t : t \in W_j\}) \quad (4.2)$$

São utilizadas as 17 classes listadas na Tabela 4.3, que incluem o estado normal (classe 0), nove eventos ativos (classes 1–9) e os correspondentes estados transientes (classes 101–109). As classes 103 e 104 não aparecem no dataset.

Tabela 4.3 – Classes do estado operacional utilizadas na rotulagem das janelas.

Classe	Evento	Estado
0	Operação normal	Normal
1	Aumento abrupto de BSW	Ativo
2	Fechamento espúrio da DHSV	Ativo
3	Golfadas severas	Ativo
4	Instabilidade de fluxo	Ativo
5	Perda rápida de produtividade	Ativo
6	Restrição rápida no PCK	Ativo
7	Incrustação no PCK	Ativo
8	Hidrato na linha de produção	Ativo
9	Hidrato na linha de serviço	Ativo
101	Aumento abrupto de BSW	Transiente
102	Fechamento espúrio da DHSV	Transiente
105	Perda rápida de produtividade	Transiente
106	Restrição rápida no PCK	Transiente
107	Incrustação no PCK	Transiente
108	Hidrato na linha de produção	Transiente
109	Hidrato na linha de serviço	Transiente

4.5 Treinamento e Validação

São avaliados quatro modelos de duas famílias distintas. O *Random Forest* e o *XGBoost* operam sobre as 88 *features* estatísticas extraídas das janelas deslizantes; a CNN-1D e a CNN-LSTM recebem diretamente a janela normalizada de 300×8 amostras. Todos os modelos adotam predições *out-of-fold* (OOF): em cada um dos cinco *folds*, o modelo é treinado nos demais poços e prediz sobre o *fold* de teste, de modo que cada janela seja avaliada por um modelo que nunca a viu durante o treino.

O 3W Dataset é altamente desbalanceado (Apêndice B): a classe Normal representa 22,7% das janelas, enquanto a classe 7 (Incrustação no PCK, ativa) contém apenas 914 janelas (0,2% do total). Por isso, em todos os modelos, o desbalanceamento é compensado por pesos de amostra inversamente proporcionais à frequência de cada classe, calculados via `compute_class_weight('balanced')` a partir das instâncias de treino de cada *fold*.

A métrica principal de comparação entre modelos é o F1-macro (definido na Seção 3.8), que trata todas as classes com igual peso e, portanto, é mais sensível ao desempenho nas classes minoritárias do que a acurácia global.

4.5.1 Estratégia de Validação Cruzada

A separação treino/teste adota *GroupKFold* com $K = 5$ *folds* para o RF e o *XGBoost*, agrupando as janelas pelo identificador da instância (`instance_id`). Isso garante que janelas pertencentes a mesma instância nunca estejam simultaneamente no conjunto de treino e no de teste, evitando *data leakage* entre poços.

O agrupamento por instância foi preferido ao agrupamento por poço físico por uma limitação do próprio dataset: o 3W Dataset conta com apenas 40 poços físicos, e classes raras como BSW e Restrição no PCK possuem instâncias reais concentradas em dois ou três poços cada. Com $K = 5$, agrupar por poço físico resultaria em *folds* de treino sem nenhum exemplo de algumas dessas classes, inviabilizando o treinamento. O agrupamento por instância impede o vazamento temporal dentro de cada episódio e mantém representação de todas as classes em todos os *folds*, ao custo de que episódios distintos de um mesmo poço físico possam cair em *folds* diferentes.

4.5.2 Configuração por Modelo

Random Forest. Utiliza `max_features='sqrt'`, resultando em $\sqrt{88} \approx 9$ *features* candidatas por divisão de nó. A busca de hiperparâmetros segue a estrutura de validação cruzada aninhada (*Nested CV*), com $K_{\text{out}} = 5$ *folds* externos para estimativa de desempenho e $K_{\text{in}} = 3$ *folds* internos para busca via *RandomizedSearchCV* com $N = 20$ combinações, totalizando $5 \times 3 \times 20 = 300$ treinamentos. Essa separação garante que os dados do *fold* de teste ex-

terno nunca participem da seleção de hiperparâmetros, produzindo estimativa imparcial do desempenho.

XGBoost. Emprega a função de perda `multi:softmax` para classificação com os 17 estados, com rótulos codificados por `LabelEncoder` e o parâmetro `tree_method='hist'` para eficiência computacional com centenas de milhares de amostras. A busca de hiperparâmetros segue a mesma estrutura de *Nested CV* do RF.

CNN-1D. Adota a arquitetura FCN de Wang, Yan e Oates (2017) com *padding* que replica as extremidades do sinal. A configuração é fixa, sem busca de hiperparâmetros, com otimizador Adam (Kingma; Ba, 2015), *learning rate* (LR) de 10^{-3} e *batch size* de 256 amostras. Em cada *fold*, 15% das instâncias são reservadas para validação; o critério de parada monitora o F1-macro com paciência de 15 épocas (número máximo de épocas consecutivas sem melhora antes de encerrar o treinamento), e a LR é reduzida pela metade quando o F1-macro estagna por 7 épocas consecutivas.

CNN-LSTM. Acrescenta à extração convolucional uma camada LSTM alimentada por 75 passos temporais comprimidos (de 300 originais), com o objetivo de capturar a progressão temporal dos estados. Os hiperparâmetros (`lstm_units`, `dropout_rate`, `learning_rate`, `batch_size`) são otimizados via Optuna (Akiba *et al.*, 2019) com 30 *trials* no fold 0 do *GroupKFold*(5), utilizando o amostrador TPE (*Tree-structured Parzen Estimator*) e o *MedianPruner*; os valores selecionados são então fixados para o treinamento completo nos 5 *folds*. A aplicação de *Nested CV* seria inviável com os recursos computacionais disponíveis, exigindo centenas de treinos de vários minutos cada. Os critérios de parada e redução de LR são idênticos aos da CNN-1D.

A Tabela 4.4 apresenta os espaços de busca de hiperparâmetros para RF, XGBoost e CNN-LSTM, e a Tabela 4.5 resume os parâmetros de treinamento das redes neurais.

Tabela 4.4 – Espaços de busca de hiperparâmetros por modelo.

Modelo	Hiperparâmetro	Valores candidatos
RF	n_estimators	100, 200, 300
RF	max_depth	Sem limite, 10, 20, 30
RF	min_samples_leaf	1, 2, 4
RF	max_features	'sqrt', 'log2'
XGBoost	n_estimators	100, 200, 300, 500
XGBoost	max_depth	3, 4, 6, 8
XGBoost	learning_rate	0,01; 0,05; 0,1; 0,2
XGBoost	subsample	0,7; 0,8; 1,0
XGBoost	colsample_bytree	0,7; 0,8; 1,0
XGBoost	min_child_weight	1, 3, 5
CNN-LSTM	lstm_units	32, 64, 128
CNN-LSTM	dropout_rate	0,1 a 0,5 (uniforme)
CNN-LSTM	learning_rate	10^{-4} a 10^{-2} (log-uniforme)
CNN-LSTM	batch_size	256, 512

Tabela 4.5 – Configuração de treinamento das redes neurais CNN-1D e CNN-LSTM.

Parâmetro	CNN-1D (FCN)	CNN-LSTM
Otimizador	Adam	Adam
Taxa de aprendizado	10^{-3} (fixo)	$1,09 \times 10^{-3}$ (Optuna)
Tamanho do lote	256	512 (Optuna)
Épocas máximas	100	100
Paciência (parada)	15 épocas	15 épocas
Redução de LR	7 épocas, fator 0,5	7 épocas, fator 0,5
Validação	15% das instâncias	15% das instâncias

4.6 Interpretabilidade com SHAP

Para compreender quais features mais influenciam as previsões dos modelos, utiliza-se o método SHAP (*Shapley Additive Explanations*) (Lundberg; Lee, 2017). Dado uma amostra x (janela de sensores a ser explicada), o SHAP atribui a cada feature uma contribuição à previsão do modelo, de forma que:

$$f(x) = \varphi_0 + \sum_{j=1}^p \varphi_j(x) \quad (4.3)$$

onde φ_0 é o valor de base (média global do modelo), $\varphi_j(x)$ é a contribuição da feature j para a amostra x , e $p = 88$ é o número de features. Para os modelos RF e XGBoost, os valores SHAP são calculados de forma exata pelo TreeExplainer (Lundberg *et al.*, 2020), que percorre diretamente as estruturas das árvores.

O cálculo é realizado sobre uma amostra estratificada de 3.000 janelas do conjunto OOF, selecionadas proporcionalmente por classe para garantir representação de todas as 17 classes. A análise de importância global agrega os valores SHAP por sensor, somando as contribuições absolutas médias das 11 features de cada sensor para cada estado operacional.

4.7 Comparação de Métodos de Filtragem

Para quantificar o impacto da escolha do método de filtragem no desempenho do classificador, são treinados três modelos XGBoost com configurações idênticas de hiperparâmetros, diferindo apenas na etapa de filtragem de sinal, conforme a Tabela 4.6.

Tabela 4.6 – Configurações comparadas na análise de métodos de filtragem de sinal.


Configuração	Método	Parâmetro
Sem Filtro	Nenhum	—
Estatístico	Filtro adaptativo (Equação 3.15)	$\sigma = 0,5$
Gaussiano	gaussian_filter1d (padrão)	$\sigma = 2,0$ amostras

Os mesmos hiperparâmetros ótimos do modelo Gaussiano são utilizados nas três configurações, garantindo que qualquer diferença de desempenho seja atribuível exclusivamente ao método de filtragem, não à otimização de hiperparâmetros.

Os resultados são comparados em termos de F1-macro, F1-weighted e acurácia, tanto globalmente quanto por classe, para identificar quais estados operacionais são mais sensíveis à escolha do método de filtragem.

A Figura 4.2 ilustra o efeito dos três métodos de filtragem sobre os sinais de um poço da Classe 8 (Hidrato na Linha de Produção). O filtro Gaussiano promove suavização uniforme, atenuando tanto ruídos de alta frequência quanto variações abruptas características de eventos. O filtro estatístico adaptativo preserva as transições rápidas enquanto suprime oscilações de pequena amplitude, comportamento descrito pela Equação 3.16.

Figura 4.2 – Comparação visual dos três métodos de filtragem sobre sinais do poço WELL-00028 (Classe 8 – Hidrato na Linha de Produção).



5 Resultados e Análises

Este capítulo apresenta os resultados obtidos pelo pipeline de classificação de estado operacional descrito no Capítulo 4. A análise está organizada em três partes: (i) comparação entre os quatro modelos avaliados (RF, XGBoost, CNN-LSTM e CNN-1D (FCN)), com foco nas métricas globais, no desempenho por classe e nas matrizes de confusão; (ii) análise comparativa de métodos de filtragem de sinal; e (iii) análise de interpretabilidade por SHAP e MDI.

5.1 Comparação entre Modelos

5.1.1 Métricas Globais

A Tabela 5.1 apresenta as métricas globais dos quatro modelos avaliados com filtro Gaussiano ($\sigma = 2,0$), ou seja, F1-macro, F1-ponderado e acurácia calculados sobre todas as classes simultaneamente.

Tabela 5.1 – Métricas globais dos modelos avaliados (filtro Gaussiano, $\sigma = 2,0$).

Modelo	F1-macro	F1-ponderado	Acurácia
Random Forest	0,8716	0,9308	0,9322
XGBoost	0,9082	0,9361	0,9364
CNN-LSTM	0,7058	0,7607	0,7557
CNN-1D (FCN)	0,6685	0,7168	0,7107

Os modelos baseados em *features* (RF e XGBoost) superam as redes neurais em todas as métricas, com vantagem de aproximadamente 20 p.p. de F1-macro em relação à melhor rede neural (CNN-LSTM). Na comparação entre os modelos clássicos, o XGBoost supera o RF em +3,7 p.p. de F1-macro, liderando também em F1-ponderado e acurácia.

Entre as redes neurais, a CNN-LSTM supera a CNN-1D em +3,7 p.p. de F1-macro; a memória sequencial da LSTM captura a evolução temporal do sinal ao longo das janelas de 300 s, conferindo vantagem especialmente nas classes de transiente, nas quais a CNN-1D, sem memória recorrente, apresenta maior dificuldade.

5.1.2 Desempenho por Classe

A Tabela 5.2 detalha o F1-score por classe para os quatro modelos, evidenciando onde cada abordagem apresenta vantagens e limitações. Para RF e XGBoost, os valores

correspondem às predições OOF concatenadas dos cinco *folds* externos do *Nested CV*.

Tabela 5.2 – F1-score por classe operacional para todos os modelos (filtro Gaussiano).

Cl.	Evento (Estado)	RF	XGBoost	CNN-LSTM	CNN-1D
0	Normal	0,9022	0,9145	0,7459	0,6116
1	BSW (Ativo)	0,9410	0,9389	0,6768	0,6692
2	DHSV (Ativo)	0,9722	0,9729	0,9318	0,8961
3	Golfadas (Ativo)	0,9641	0,9674	0,9095	0,9170
4	Inst. Fluxo (Ativo)	0,9188	0,8988	0,6869	0,4727
5	Prod. Rápida (Ativo)	0,9789	0,9819	0,8992	0,8881
6	PCK Restr. (Ativo)	0,9904	0,9901	0,5940	0,6924
7	PCK Incrust. (Ativo)	0,0086	0,5712	0,3202	0,1816
8	Hidrato Prod. (Ativo)	0,8548	0,8497	0,8006	0,7944
9	Hidrato Serv. (Ativo)	0,9909	0,9895	0,9544	0,9404
101	BSW (Trans.)	0,9492	0,9289	0,6961	0,6848
102	DHSV (Trans.)	0,7864	0,8285	0,4809	0,3853
105	Prod. Rápida (Trans.)	0,8928	0,8899	0,5701	0,5929
106	PCK Restr. (Trans.)	0,9772	0,9775	0,4545	0,4515
107	PCK Incrust. (Trans.)	0,9073	0,9047	0,7061	0,6071
108	Hidrato Prod. (Trans.)	0,8204	0,8724	0,7544	0,7638
109	Hidrato Serv. (Trans.)	0,9616	0,9628	0,8170	0,8165

5.1.3 Análise das Matrizes de Confusão

As Figuras 5.1 e 5.2 apresentam as matrizes de confusão do RF e do XGBoost; as Figuras 5.3 e 5.4 apresentam as matrizes da CNN-LSTM e da CNN-1D. Os valores estão normalizados pela quantidade de amostras de cada classe, de modo que os valores da diagonal correspondem ao recall de cada classe e a soma de cada linha é 1. As matrizes completas estão reunidas no Apêndice D.

Figura 5.1 – Matriz de confusão do RF (filtro Gaussiano, $\sigma = 2,0$, avaliação OOF).




Figura 5.2 – Matriz de confusão do XGBoost (filtro Gaussiano, $\sigma = 2,0$, avaliação OOF).




Figura 5.3 – Matriz de confusão da CNN-LSTM (filtro Gaussiano, $\sigma = 2,0$, avaliação OOF).





Figura 5.4 – Matriz de confusão da CNN-1D (FCN, filtro Gaussiano, $\sigma = 2,0$, avaliação OOF).



A comparação visual entre as quatro matrizes revela um padrão estrutural entre as famílias de modelos. No RF e no XGBoost, os erros se concentram em poucos pares de classes com semelhança física reconhecida, sobretudo estados transientes confundidos com a operação normal adjacente, e a grande maioria das classes apresenta diagonal próxima de 1,0, com as demais células da linha praticamente zeradas.

Nas redes neurais, os erros são mais difusos: diversas classes apresentam confusões simultâneas com múltiplas outras classes, resultando em matrizes com valores fora da diagonal distribuídos por várias colunas. Esse espalhamento é consistente com a diferença de ≈ 20 p.p. de F1-macro entre as famílias e indica que, com o volume de dados disponível no 3W Dataset, as redes neurais ainda não consolidaram fronteiras de decisão bem definidas para todas as 17 classes.

5.1.4 A Classe 7 — Incrustação no PCK (Ativo)

A classe 7 (Incrustação no PCK, estado ativo) é o caso mais desafiador do dataset, com apenas 914 janelas (0,2% do total; distribuição completa no Apêndice B). O RF obteve F1 = 0,009; o XGBoost alcançou F1 = 0,571; a CNN-LSTM atingiu F1 = 0,320; e a CNN-1D ficou em F1 = 0,182.

O mecanismo pelo qual o RF falha nessa classe deve-se ao *bagging*: com apenas ≈ 180 janelas da classe 7 por *fold*, a maioria das amostras *bootstrap* de cada árvore não contém exemplos suficientes para aprender o padrão discriminante. O XGBoost, por ser sequencial, foca iterativamente nos exemplos que os modelos anteriores erraram, permitindo que os exemplos raros da classe 7 recebam atenção progressiva. As redes neurais ficam em posição intermediária: a CNN-LSTM, com sua memória temporal, aprende parcialmente a assinatura de degradação gradual do choke, mas com apenas 914 janelas no dataset inteiro não dispõe de exemplos suficientes para consolidar esse aprendizado.

5.1.5 Análise: Features Artesanais vs Representações Aprendidas

Os resultados confirmam que, para o 3W Dataset, as 88 *features* artesanais superam as representações aprendidas pelas redes neurais. Três fatores estruturais explicam essa diferença:

1. **Eficiência de dados:** *features* como T-TPT_std e diff2_std comprimem 300 amostras temporais em um único número informativo. As redes neurais precisam de muito mais exemplos para descobrir implicitamente que a variabilidade e a aceleração de T-TPT são discriminativas;
2. **Transientes vs estados ativos:** a distinção entre transiente e evento ativo é primariamente uma questão de taxa de variação, capturada diretamente por diff1_std e diff2_std. As convoluções e a LSTM aprendem padrões de forma do sinal, não diferenciais explícitos, o que explica déficit acentuado nos transientes;
3. **Desbalanceamento severo:** com razão de desbalanceamento de 112:1, o XGBoost compensa via *boosting* sequencial. As redes neurais, mesmo com *sample_weight*, não possuem mecanismo equivalente de realocação progressiva de gradiente para classes raras.

A CNN-LSTM supera a CNN-1D em 12 das 17 classes, com ganho mais expressivo nos transientes, evidenciando que a memória temporal da LSTM contribui especialmente para distinguir fases de progressão de falha. Entretanto, o gap em relação ao XGBoost permanece elevado, indicando que arquiteturas de aprendizado profundo mais sofisticadas ou conjuntos de dados maiores seriam necessários para competir com os modelos baseados em *features* artesanais neste domínio.

5.2 Análise Comparativa de Métodos de Filtragem

5.2.1 Métricas Globais dos Três Regimes

A Tabela 5.3 compara as métricas globais dos três modelos XGBoost treinados com diferentes regimes de filtragem.

Tabela 5.3 – Métricas globais do XGBoost para os três regimes de filtragem de sinal.

Filtragem	F1-macro	F1-weighted	Acurácia
Sem Filtro	0,9065	0,9339	0,9345
Estatístico ($\sigma = 0,5$)	0,9067	0,9401	0,9402
Gaussiano ($\sigma = 2,0$)	0,9082	0,9361	0,9364

Os três regimes apresentam F1-macro muito próximos (variação máxima de 0,0017), indicando que a filtragem de sinal tem impacto global modesto. Contudo, o filtro estatístico apresenta a melhor F1-weighted (0,9401) e acurácia (0,9402), evidenciando benefício para as classes mais frequentes.

5.2.2 Análise por Classe

A Tabela 5.4 apresenta o F1-score por classe para os três regimes, evidenciando que o impacto da filtragem é heterogêneo entre as classes.

Tabela 5.4 – F1-score por classe operacional para os três regimes de filtragem (XGBoost).

Cl.	Evento (Estado)	Gaussiano	Sem Filtro	Estatístico
0	Normal	0,9145	0,9091	0,9168
1	BSW (Ativo)	0,9389	0,9407	0,9403
2	DHSV (Ativo)	0,9729	0,9733	0,9648
3	Golfadas (Ativo)	0,9674	0,9757	0,9588
4	Inst. Fluxo (Ativo)	0,8988	0,9063	0,8894
5	Prod. Rápida (Ativo)	0,9819	0,9853	0,9804
6	PCK Restr. (Ativo)	0,9901	0,9917	0,9911
7	PCK Incrust. (Ativo)	0,5712	0,5260	0,5761
8	Hidrato Prod. (Ativo)	0,8497	0,8508	0,8443
9	Hidrato Serv. (Ativo)	0,9895	0,9899	0,9879
101	BSW (Trans.)	0,9289	0,9281	0,9544
102	DHSV (Trans.)	0,8285	0,8646	0,7718
105	Prod. Rápida (Trans.)	0,8899	0,8955	0,8869
106	PCK Restr. (Trans.)	0,9775	0,9794	0,9786
107	PCK Incrust. (Trans.)	0,9047	0,9074	0,9210
108	Hidrato Prod. (Trans.)	0,8724	0,8278	0,8914
109	Hidrato Serv. (Trans.)	0,9628	0,9586	0,9605

5.2.3 Comparação para a CNN-LSTM

A Tabela 5.5 compara as métricas globais da CNN-LSTM treinada nos três regimes de filtragem de sinal.

Tabela 5.5 – Métricas globais da CNN-LSTM para os três regimes de filtragem de sinal.

Filtragem	F1-macro	F1-weighted	Acurácia
Sem Filtro	0,6778	0,7398	0,7344
Estatístico ($\sigma = 0,5$)	0,6802	0,7369	0,7316
Gaussiano ($\sigma = 2,0$)	0,7058	0,7607	0,7557

Ao contrário do XGBoost, cujas *features* agregam estatísticas sobre a janela inteira, a CNN-LSTM processa o sinal amostra por amostra, o que a torna mais sensível às características do pré-processamento. Nos três regimes, o filtro Gaussiano produz as melhores métricas globais, com ganho de +2,8 p.p. em F1-macro sobre o filtro estatístico e +2,8 p.p. sobre o sinal sem filtro.

A Tabela 5.6 detalha o F1-score por classe para os três regimes, evidenciando que o impacto da filtragem é heterogêneo entre os estados operacionais.

Tabela 5.6 – F1-score por classe operacional para os três regimes de filtragem (CNN-LSTM).

Cl.	Evento (Estado)	Sem Filtro	Estatístico	Gaussiano
0	Normal	0,7020	0,6903	0,7459
1	BSW (Ativo)	0,6646	0,6666	0,6768
2	DHSV (Ativo)	0,8825	0,9074	0,9318
3	Golfadas (Ativo)	0,8917	0,9043	0,9095
4	Inst. Fluxo (Ativo)	0,6322	0,6452	0,6869
5	Prod. Rápida (Ativo)	0,8775	0,8875	0,8992
6	PCK Restr. (Ativo)	0,6103	0,6027	0,5940
7	PCK Incrust. (Ativo)	0,2014	0,2170	0,3202
8	Hidrato Prod. (Ativo)	0,7612	0,7867	0,8006
9	Hidrato Serv. (Ativo)	0,9469	0,9454	0,9544
101	BSW (Trans.)	0,6877	0,6582	0,6961
102	DHSV (Trans.)	0,3944	0,4180	0,4809
105	Prod. Rápida (Trans.)	0,5581	0,5522	0,5701
106	PCK Restr. (Trans.)	0,4449	0,4471	0,4545
107	PCK Incrust. (Trans.)	0,6706	0,6908	0,7061
108	Hidrato Prod. (Trans.)	0,7732	0,7443	0,7544
109	Hidrato Serv. (Trans.)	0,8234	0,7991	0,8170

5.3 Análise de Interpretabilidade


Esta seção analisa a interpretabilidade dos modelos por meio de dois métodos complementares. O MDI (*Mean Decrease in Impurity*) mede a frequência e o ganho de pureza com que cada feature é utilizada nas divisões das árvores, refletindo diretamente a estratégia de aprendizado adotada por cada *ensemble*. Os valores SHAP (*SHapley Additive exPlanations*) quantificam a contribuição marginal de cada feature para cada predição individual, sendo agnósticos à estrutura interna do modelo e representando o impacto de cada feature nas saídas em termos de variação na probabilidade predita. Os dois métodos se complementam: o MDI revela quais features o modelo utiliza com mais frequência, enquanto o SHAP indica quanto cada feature influencia as predições em média.

Os gráficos de comparação RF vs XGBoost com valores SHAP utilizam escalas diferentes, o que requer uma observação. O RF produz probabilidades de classe como saída, e o *TreeExplainer* computa os valores SHAP nesse espaço (escala $[0, 1]$). O XGBoost opera internamente em escala de *log-odds* e aplica *softmax* ao final, e o *TreeExplainer* calcula os valores SHAP nessa escala sem restrição de domínio. Para a classe 7 ($f \approx 0,2\%$), por exemplo, o valor base do XGBoost é $\log(0,002/0,998) \approx -6$, e as contribuições individuais chegam a ± 3 unidades de *log-odds*. Essa diferença não indica que o XGBoost encontrou um sinal mais forte, apenas que as unidades são distintas. As comparações válidas são sempre entre features *dentro do mesmo modelo*.

5.3.1 Importância Global por Sensor

A Figura 5.5 apresenta a importância global por sensor, calculada como a média dos valores SHAP absolutos agregados sobre as 17 classes.

Figura 5.5 – Importância global por sensor (média dos valores SHAP absolutos).



O sensor T-TPT (temperatura na árvore de natal molhada) é o mais informativo nos dois modelos. A árvore de natal molhada é o ponto de instrumentação mais próximo da coluna de produção onde perturbações no escoamento se manifestam termicamente de forma clara: restrições, transientes de pressão e alterações na composição do fluido produzido geram

padrões distintos e reconhecíveis de temperatura nesse sensor. Os sensores de pressão P-PDG e P-TPT ocupam as posições seguintes no RF; no XGBoost, a ordem se inverte entre P-TPT e P-PDG, mas ambos ficam no topo.


Uma correlação relevante emerge ao comparar a importância SHAP de cada sensor com sua disponibilidade de dados, apresentada na Figura 2.9. Os três sensores de menor cobertura no dataset são também os três de menor importância em ambos os modelos: T-PDG (24,4% de cobertura) ocupa o último lugar com ampla margem, seguido de QGL (32,4%) e P-JUS-CKGL (37,3%). O caso do T-PDG é o mais ilustrativo: embora a temperatura de fundo de poço seja fisicamente relevante para o monitoramento de eventos, a ausência de leituras em mais de 75% das amostras limita drasticamente a capacidade do modelo de aprender padrões associados a esse sensor.

Em contrapartida, os cinco sensores com cobertura acima de 70% (P-TPT, P-PDG, P-MON-CKP, T-TPT e T-JUS-CKP) concentram-se consistentemente no topo do ranking de importância nos dois modelos, reforçando que a disponibilidade de dados é um fator determinante para que um sensor seja efetivamente explorado pelos modelos de árvore.

5.3.2 Importância Global das Features

A Figura 5.6 apresenta as 20 features com maior importância global por MDI (*Mean Decrease in Impurity*) para RF e XGBoost, revelando diferenças marcantes entre os dois modelos na forma como exploram as features disponíveis.

Figura 5.6 – Top 20 features por importância MDI — RF e XGBoost.



No RF, as quatro features de maior MDI são variáveis de temperatura na árvore de natal molhada em diferentes escalas temporais: T-TPT_std (1º), T-TPT_diff2_std (2º), T-TPT_lqr (3º) e T-TPT_diff1_std (4º). A variabilidade de T-TPT, tanto na escala original quanto nas derivadas de primeira e segunda ordem, é o sinal mais explorado pelo RF ao longo das 17 classes, com as importâncias bem distribuídas entre os demais sensores.

No XGBoost, o perfil é radicalmente diferente: QGL_max lidera com importância $\approx 0,14$, quase o dobro de QGL_iqr em segundo ($\approx 0,07$), e todos os outros sensores ficam abaixo de 0,04. A explicação está na dinâmica do *boosting* sequencial combinada com a natureza dos eventos de hidrato na linha de serviço (classes 9 e 109): quando um hidrato bloqueia o duto de injeção de gás lift, a vazão QGL cai abruptamente, criando uma assinatura de separação muito limpa para essas classes. As primeiras árvores do XGBoost identificam esse padrão com ganho de informação muito alto, concentrando grande crédito de MDI em QGL_max e QGL_iqr. O RF, por sua vez, não consegue concentrar tanto esforço em um único sensor, já que cada árvore usa apenas um subconjunto aleatório de features, distribuindo a importância de forma mais homogênea.


5.3.3 SHAP para Eventos de Formação de Hidrato

A formação de hidratos de gás é um fenômeno termodinâmico: quando a temperatura cai abaixo da curva de equilíbrio de estabilidade (para uma dada pressão) na presença de gás e água livre, formam-se estruturas cristalinas sólidas capazes de bloquear progressivamente o escoamento. O 3W Dataset contém dois tipos de evento de hidrato, cada um com localização física distinta: hidrato na linha de produção (classes 8 e 108) e hidrato na linha de serviço, ou seja, no duto de injeção de gás lift (classes 9 e 109). A análise SHAP revela assinaturas de sensores completamente diferentes para os dois tipos, confirmando o conhecimento físico esperado.

5.3.3.1 Hidrato na Linha de Produção — Classes 8 e 108

A Figura 5.7 apresenta os valores SHAP para a classe 8 (Hidrato Prod. Ativo), e a Figura 5.8 para a classe 108 (Hidrato Prod. Transiente).

Figura 5.7 – Valores SHAP para a classe 8 (Hidrato na Linha de Produção, Ativo) — RF vs XGBoost.




Para o estado ativo (classe 8), P-MON-CKP_max é a feature mais importante nos dois modelos. Uma hipótese é que, quando o hidrato bloqueia a linha de produção entre a

árvore de natal molhada e o manifold, menos fluido chegaria ao manifold e a pressão nesse ponto cairia abaixo do normal. Nesse cenário, a pressão máxima registrada durante a janela (P-MON-CKP_max) funcionaria como um indicador de quanto fluxo está chegando ao manifold: valores deprimidos sugeririam restrição de escoamento pelo plugue.

No RF, as posições seguintes são ocupadas por várias estatísticas de pressão na árvore de natal molhada (P-TPT: mediana, máximo, mínimo e IQR), junto com features de temperatura no mesmo ponto (T-TPT_std e T-TPT_mean). Isso sugere que o bloqueio pode afetar simultaneamente a pressão e a temperatura na árvore de natal molhada. Uma possível explicação para os valores baixos de T-TPT_std (pontos azuis com SHAP positivo no RF) é que a temperatura teria ficado praticamente parada, o que ocorreria caso o hidrato interrompesse o fluxo de fluido quente vindo do poço.

No XGBoost, depois de P-MON-CKP_max, as features mais importantes são P-TPT_min, T-JUS-CKP_min, T-TPT_iqr e T-JUS-CKP_max. Os valores SHAP mostram que valores altos de P-TPT_min e baixos de P-MON-CKP contribuem para a classe 8. Uma interpretação possível é que o hidrato forme um bloqueio entre a árvore de natal molhada e o manifold: com a linha obstruída, a pressão se acumularia no lado da árvore de natal molhada (P-TPT alto) enquanto menos fluido chegaria ao manifold (P-MON-CKP baixo), criando um diferencial de pressão ao longo do plugue que o XGBoost usaria como principal assinatura do evento.

Figura 5.8 – Valores SHAP para a classe 108 (Hidrato na Linha de Produção, Transiente) — RF vs XGBoost.



Para o estado transiente (classe 108), P-MON-CKP_max deixa de ser o principal indicador e as variáveis de temperatura passam ao topo. Em ambos os modelos, valores baixos de T-TPT_std contribuem para a classe 108. Uma hipótese é que, em operação normal, a temperatura na árvore de natal molhada oscila com variações naturais da produção. No transiente de hidrato, o resfriamento causado pelo plugue em formação pode começar a dominar o sinal, que passaria a variar menos do que o usual. Nesse caso, baixa variabilidade de T-TPT não indicaria temperatura parada como no estado ativo, mas sim temperatura sendo puxada para baixo de forma consistente, com menos oscilação do que em condições

normais.


No RF, as features mais importantes são T-TPT_std, T-TPT_iqr e T-JUS-CKP_max, seguidas por variáveis de QGL (QGL_max, QGL_mean e QGL_median). A presença de features de QGL é inesperada para um evento na linha de produção, mas pode refletir o fato de que variações na injeção de gás lift afetam o perfil térmico do poço, tornando o QGL um indicador indireto das condições que favorecem a formação de hidrato.

No XGBoost, além de T-TPT_std, destacam-se T-JUS-CKP_diff2_std, T-JUS-CKP_max e QGL_max. Valores baixos de T-JUS-CKP_diff2_std podem indicar que a temperatura a jusante do choke está caindo a uma taxa uniforme, sem oscilações na velocidade de queda. Uma hipótese é que esse padrão reflita o crescimento progressivo do hidrato: o plugue se formaria de maneira gradual, restringindo o fluxo de forma estável e resultando em um resfriamento consistente. Essa capacidade de detectar a uniformidade do resfriamento pode contribuir para o ganho do XGBoost sobre o RF nessa classe ($F1 = 0,872$ vs $0,820$, $+5,2$ p.p.).

5.3.3.2 Hidrato na Linha de Serviço — Classes 9 e 109

A Figura 5.9 apresenta os valores SHAP para a classe 9 (Hidrato Serv. Ativo). O contraste com a classe 8 é imediato: em vez de features de temperatura, as variáveis dominantes são QGL_max, QGL_mean e P-JUS-CKGL (pressão a jusante do choke de gás lift).

Figura 5.9 – Valores SHAP para a classe 9 (Hidrato na Linha de Serviço, Ativo) — RF vs XGBoost.



A linha de serviço é o duto pelo qual o gás lift é injetado no poço. Quando hidratos se formam nessa linha, o fluxo de gás pode ser diretamente restringido. Os valores baixos de QGL_max e QGL_mean (pontos azuis com SHAP positivo em ambos os modelos) sugerem que, nessas janelas, a vazão de gás lift está reduzida, o que seria a assinatura direta do bloqueio na linha de injeção.


No XGBoost, P-JUS-CKGL_max aparece na segunda posição com valores altos contribuindo para a classe 9. Uma hipótese é que, com o hidrato bloqueando a linha mais abaixo, a pressão se acumule entre o choke de gás lift e o plugue, elevando a pressão nesse trecho. Isso criaria um padrão característico: QGL baixo e P-JUS-CKGL alto ao mesmo tempo, ou seja,

pressão alta na linha mas com pouco ou nenhum fluxo passando, o que seria a assinatura do bloqueio por hidrato. No RF, além das features de nível de QGL (QGL_max, QGL_mean), destaca-se P-JUS-CKGL_diff1_std, que mede a variabilidade da taxa de variação da pressão a jusante do choke de gás lift. Essa feature pode capturar oscilações no comportamento da pressão de injeção causadas pelo bloqueio parcial ou intermitente do hidrato.

Notavelmente, nenhuma feature de temperatura ou pressão da linha de produção (T-TPT, T-JUS-CKP, P-MON-CKP) aparece entre as mais importantes no RF, e apenas marginalmente no XGBoost. Isso é consistente com a hipótese de que o evento está localizado no circuito de injeção, não afetando diretamente os sensores da linha de produção.

A Figura 5.10 apresenta os valores SHAP para a classe 109 (Hidrato Serv. Transiente).

Figura 5.10 – Valores SHAP para a classe 109 (Hidrato na Linha de Serviço, Transiente) — RF vs XGBoost.



Para o estado transiente de hidrato na linha de serviço (classe 109), as features de QGL dominam no RF com um padrão distinto do observado na fase ativa: valores baixos de QGL_kurtosis e valores altos de QGL_min e QGL_mean contribuem positivamente para essa classe. Uma hipótese é que, no estágio inicial da obstrução, a vazão de gás lift ainda se mantém relativamente elevada e com distribuição mais regular (menor curtose), em contraste com a fase ativa (classe 9), em que o bloqueio já reduziu o fluxo de forma consistente. No RF, pressões baixas de PDG (P-PDG_mean, P-PDG_max) também contribuem para a classe 109, o que pode refletir variações de pressão de fundo associadas ao início do processo de obstrução.

No XGBoost, além das features de variabilidade de QGL (QGL_lqr, QGL_diff2_std, QGL_std), a feature P-JUS-CKGL_max com valores altos também apresenta contribuição relevante para a classe 109. Uma hipótese é que, à medida que o hidrato começa a restringir o escoamento na linha de serviço, a pressão na saída da válvula de gás lift começa a aumentar, refletindo a resistência crescente ao escoamento antes do bloqueio completo, de forma análoga ao acúmulo de pressão observado na fase ativa (classe 9).

Em síntese, a análise SHAP sugere que os dois modelos capturam padrões fisicamente coerentes com a localização de cada tipo de hidrato: para as classes 8 e 108, os sensores

de temperatura e pressão da linha de produção são os mais informativos, enquanto para as classes 9 e 109, a vazão de gás lift e a pressão na linha de serviço assumem esse papel. A distinção entre fase transiente e fase ativa também se reflete nas features selecionadas: para o hidrato na linha de produção, o transiente é caracterizado por baixa variabilidade de temperatura, enquanto a fase ativa exibe um diferencial de pressão mais pronunciado; para o hidrato na linha de serviço, o transiente ainda apresenta vazão relativamente elevada e mais regular, ao passo que a fase ativa é marcada pela queda consistente do fluxo de gás lift.

6 Conclusões

Este trabalho desenvolveu um pipeline completo de aprendizado de máquina para a classificação do estado operacional de poços de petróleo *offshore*, utilizando o 3W Dataset como base de dados. A seguir, apresentam-se a síntese dos resultados, as contribuições do trabalho, as limitações identificadas e os direcionamentos para trabalhos futuros.

6.1 Síntese dos Resultados

O pipeline desenvolvido é capaz de classificar, a partir de uma janela de 300 segundos de dados de sensores, o estado operacional de um poço entre 17 categorias (operação normal, nove eventos ativos e sete estados transientes) com F1-macro de 0,8812 (XGBoost, filtro Gaussiano).

Os principais resultados foram:

- O XGBoost obteve o melhor F1-macro entre os modelos avaliados (0,9082), superando o RF em +3,7 p.p. (0,8716) e as redes neurais em ≈ 20 p.p. A vantagem mais expressiva foi na classe 7 (Incrustação no PCK, ativo), onde o F1 saltou de 0,009 (RF) para 0,571, via *boosting* sequencial que foca progressivamente nos exemplos mais difíceis;
- A CNN-LSTM obteve F1-macro de 0,706, superando a CNN-1D (FCN) em +3,7 p.p. (0,6685). O ganho da CNN-LSTM sobre a CNN-1D foi mais expressivo nos estados transientes, onde a memória temporal da LSTM contribui para distinguir fases de progressão de falha. Ambas as redes neurais ficaram ≈ 20 p.p. abaixo dos modelos baseados em *features* artesanais;
- A comparação entre famílias de modelos revelou que as *features* artesanais de derivada (*diff1_std*, *diff2_std*) são o principal fator diferencial: elas capturam explicitamente a taxa de variação do sinal, que distingue transientes de estados ativos. As redes neurais precisariam de dados muito mais abundantes para aprender esses padrões implicitamente;
- A comparação de métodos de filtragem mostrou impacto modesto no XGBoost (variação máxima de 0,0017 em F1-macro), com o filtro estatístico beneficiando eventos de dinâmica lenta e sem filtro sendo superior para dinâmica rápida. Na CNN-LSTM, o impacto foi maior: filtro Gaussiano produziu F1-macro de 0,706 contra 0,680 com o filtro estatístico ($-2,6$ p.p.), evidenciando maior sensibilidade da rede recorrente ao tipo de pré-processamento;
- A análise SHAP confirmou que os modelos aprenderam padrões com significado físico: as features mais relevantes para cada classe correspondem consistentemente aos

sensores diretamente afetados por aquele tipo de evento, e não a correlações espúrias do conjunto de dados.

6.2 Contribuições

A principal contribuição deste trabalho é um sistema de detecção precoce de falhas em poços de petróleo *offshore*: ao classificar o estado operacional em 17 categorias (operação normal, evento ativo e transiente por tipo de falha), o pipeline identifica a progressão de uma anomalia antes de seu estado crítico, ampliando a janela de intervenção disponível para a equipe de operação e potencialmente reduzindo paradas não planejadas e seus custos associados.

Do ponto de vista metodológico, o trabalho contribui com uma comparação sistemática entre quatro abordagens de aprendizado de máquina sobre o 3W Dataset. A separação treino-teste por poço (*GroupKFold*) garante que as métricas reportadas reflitam o desempenho esperado em poços não vistos pelo modelo, tornando os resultados aplicáveis ao contexto de monitoramento contínuo de novos equipamentos. A análise comparativa de três regimes de filtragem de sinal oferece, ainda, diretrizes práticas de pré-processamento segundo a dinâmica temporal do evento a ser detectado.

A interpretabilidade via SHAP conecta as decisões do modelo ao comportamento físico do sistema: as *features* mais relevantes para cada classe correspondem às variáveis diretamente afetados por aquele tipo de evento, confirmando que os modelos aprenderam padrões com significado físico. Isso é especialmente relevante em aplicações industriais, onde a aceitação do sistema pelo operador depende da capacidade de explicar os alertas em termos das variáveis monitoradas.

6.3 Limitações

- **Classe 7 — Incrustação no PCK (ativo):** mesmo com o melhor modelo, o F1 de 0,571 indica que $\approx 43\%$ das janelas desse evento não são detectadas corretamente. O baixo suporte (914 janelas, 0,2% do dataset) limita o aprendizado mesmo com balanceamento de pesos, e esse problema tende a persistir enquanto o volume de dados reais dessa falha permanecer reduzido;
- **Redes neurais limitadas por volume de dados:** a CNN-LSTM e a CNN-1D ficaram ≈ 20 p.p. abaixo dos modelos baseados em *features* artesanais, especialmente nos estados transientes. Esse déficit não é estrutural das arquiteturas, mas reflexo do volume de dados disponível no 3W Dataset.
- **Imprecisão nos rótulos de transiente (*label noise*):** os rótulos de início do estado transiente foram atribuídos retroativamente por especialistas, e os sensores indicam o

desenvolvimento da anomalia vários minutos antes do primeiro rótulo oficial. Isso faz com que as métricas de F1 para classes transientes sejam subestimadas, pois janelas fisicamente anômalas são penalizadas como erros ao serem preditas corretamente pelo modelo;

- **Influência de instâncias simuladas no desempenho:** parte do 3W Dataset é composta por instâncias simuladas e desenhadas manualmente, cujos padrões tendem a ser mais regulares e menos ruidosos do que os observados em operações reais. Portanto, as métricas reportadas podem superestimar o desempenho esperado em campo, onde a variabilidade dos sinais é substancialmente maior.

6.4 Trabalhos Futuros

Com base nos resultados e nas limitações identificadas, propõem-se os seguintes direcionamentos:

- **Arquiteturas de aprendizado profundo mais avançadas:** avaliar modelos como o *Temporal Fusion Transformer* e arquiteturas baseadas em atenção (*TimesNet*), que combinam memória temporal com mecanismos de atenção multi-escala. A CNN-LSTM avaliada neste trabalho já superou a CNN-1D FCN nos transientes, mas ainda fica distante dos modelos baseados em *features* artesanais; arquiteturas mais sofisticadas, combinadas com *data augmentation* para classes raras, podem reduzir esse gap;
- **Filtro adaptativo por tipo de evento:** dado que o impacto da filtragem é heterogêneo entre classes, investigar uma estratégia de filtragem adaptativa que selecione σ dinamicamente com base no estado atual estimado do poço;
- **Correção do *label noise* nos rótulos de transiente:** aplicar algoritmos de detecção de pontos de mudança, como PELT (*Pruned Exact Linear Time*) ([Killick; Fearnhead; Eckley, 2012](#)) ou BOCPD (*Bayesian Online Changepoint Detection*) ([Adams; MacKay, 2007](#)), para identificar automaticamente o instante real de início da anomalia diretamente nos sensores. Complementarmente, aplicar o *Confident Learning* ([Northcutt; Jiang; Chuang, 2021](#)), que usa as probabilidades preditas em validação cruzada para identificar e corrigir amostras com rótulo provável incorreto, sem necessidade de reanotação manual;
- **Validação em dados de campo reais:** testar o pipeline em dados operacionais contínuos de sistemas reais de produção, avaliando a degradação de desempenho em relação ao 3W Dataset.

Referências

- ABADI, M.; BARHAM, P.; CHEN, J.; CHEN, Z.; DAVIS, A.; DEAN, J.; DEVIN, M.; GHEMAWAT, S.; IRVING, G.; ISARD, M.; KUDLUR, M.; LEVENBERG, J.; MONGA, R.; MOORE, S.; MURRAY, D. G.; STEINER, B.; TUCKER, P.; VASUDEVAN, V.; WARDEN, P.; WICKE, M.; YU, Y.; ZHENG, X. TensorFlow: A system for large-scale machine learning. *In: Proceedings of the 12th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*. Savannah, GA, USA: USENIX Association, 2016. p. 265–283. Disponível em: <https://www.usenix.org/conference/osdi16/technical-sessions/presentation/abadi>. Citado na p. 58.
- ABRAMOWITZ, M.; STEGUN, I. A. **Handbook of Mathematical Functions with Formulas, Graphs, and Mathematical Tables**. New York: Dover Publications, 1964. ISBN 978-0-486-61272-0. Citado na p. 56.
- ADAMS, R. P.; MACKAY, D. J. C. **Bayesian Online Changepoint Detection**. 2007. ArXiv preprint. DOI [10.48550/arXiv.0710.3742](https://doi.org/10.48550/arXiv.0710.3742). Citado na p. 87.
- AKIBA, T.; SANO, S.; YANASE, T.; OHTA, T.; KOYAMA, M. Optuna: A next-generation hyperparameter optimization framework. *In: Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Anchorage, AK, USA: ACM, 2019. p. 2623–2631. DOI [10.1145/3292500.3330701](https://doi.org/10.1145/3292500.3330701). Citado na p. 65.
- Apache Software Foundation. **Apache Parquet**. 2013. Software de código aberto. Disponível em: <https://parquet.apache.org/>. Citado na p. 25.
- BAI, Y.; BAI, Q. **Subsea Engineering Handbook**. 1. ed. [S.L.]: Gulf Professional Publishing, 2012. ISBN 978-1-85617-689-7. Citado na p. 23.
- BENEDITO, V. H. L. **Desenvolvimento de um Sistema Ensemble para a Detecção e Classificação de Anomalias em Poços de Petróleo Off-Shore**. Monografia (Trabalho de Conclusão de Curso (Graduação em Engenharia Química)) — Universidade Estadual de Maringá (UEM), Maringá, 2025. Orientador: Leandro Vitor Pavão. Citado na p. 20.
- BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994. DOI [10.1109/72.279181](https://doi.org/10.1109/72.279181). Citado na p. 51.
- BIKMUKHAMETOV, T.; JÄSCHKE, J. Combining machine learning and process engineering physics towards enhanced accuracy and explainability of data-driven

- models. **Computers & Chemical Engineering**, v. 138, p. 106487, 2020. DOI [10.1016/j.compchemeng.2019.106487](https://doi.org/10.1016/j.compchemeng.2019.106487). Citado na p. 17.
- BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324). Citado nas pp. 19, 44, 45 e 46.
- BREIMAN, L.; FRIEDMAN, J.; STONE, C. J.; OLSHEN, R. A. **Classification and Regression Trees**. [S.l.]: CRC Press, 1984. ISBN 978-0-412-04841-8. Citado na p. 45.
- CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. *In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. San Francisco, CA, USA: ACM, 2016. p. 785–794. DOI [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785). Citado nas pp. 19, 47 e 58.
- CHO, K.; MERRIËNBOER, B. van; GULCEHRE, C.; BAHDANAU, D.; BOUGARES, F.; SCHWENK, H.; BENGIO, Y. Learning phrase representations using RNN encoder-decoder for statistical machine translation. *In: Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Doha, Qatar: Association for Computational Linguistics, 2014. p. 1724–1734. DOI [10.3115/v1/D14-1179](https://doi.org/10.3115/v1/D14-1179). Citado na p. 19.
- DONOHOO, D. 50 years of data science. **Journal of Computational and Graphical Statistics**, v. 26, n. 4, p. 745–766, 2017. DOI [10.1080/10618600.2017.1384734](https://doi.org/10.1080/10618600.2017.1384734). Citado na p. 17.
- EFRON, B. Bootstrap methods: Another look at the jackknife. **The Annals of Statistics**, v. 7, n. 1, p. 1–26, 1979. DOI [10.1214/aos/1176344552](https://doi.org/10.1214/aos/1176344552). Citado na p. 45.
- FAWAZ, H. I.; FORESTIER, G.; WEBER, J.; IDOUMGHAR, L.; MULLER, P.-A. Deep learning for time series classification: a review. **Data Mining and Knowledge Discovery**, v. 33, n. 4, p. 917–963, 2019. DOI [10.1007/s10618-019-00619-1](https://doi.org/10.1007/s10618-019-00619-1). Citado nas pp. 30, 50 e 52.
- GOMES, L. M. Filtro adaptativo livre de modelo para controle em malha fechada. **ISA Transactions**, 2022. DOI [10.1016/j.isatra.2022.02.026](https://doi.org/10.1016/j.isatra.2022.02.026). Citado nas pp. 55, 56 e 61.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. MIT Press, 2016. ISBN 978-0-262-03561-3. Disponível em: <https://www.deeplearningbook.org>. Citado nas pp. 18, 49, 51, 52 e 53.
- HARRIS, C. R.; MILLMAN, K. J.; WALT, S. J. van der; GOMMERS, R.; VIRTANEN, P.; COUNAPEAU, D.; WIESER, E.; TAYLOR, J.; BERG, S.; SMITH, N. J.; KERN, R.; PICUS, M.; HOYER, S.; KERKWIJK, M. H. van; BRETT, M.; HALDANE, A.; RÍO, J. F. del; WIEBE, M.; PETERSON, P.; GÉRARD-MARCHANT, P.; SHEPPARD, K.; REDDY, T.; WECKESSER, W.; ABBASI, H.; GOHLKE, C.; OLIPHANT, T. E. Array programming

- with NumPy. **Nature**, v. 585, p. 357–362, 2020. DOI [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2). Citado na p. 58.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. DOI [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735). Citado nas pp. 19 e 51.
- IOFFE, S.; SZEGEDY, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In: **Proceedings of the 32nd International Conference on Machine Learning (ICML)**. Lille, France: PMLR, 2015. p. 448–456. Disponível em: <http://proceedings.mlr.press/v37/ioffe15.html>. Citado na p. 49.
- JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. **An Introduction to Statistical Learning: with Applications in R**. [S.L.]: Springer, 2013. (Springer Texts in Statistics). ISBN 978-1-4614-7137-0. DOI [10.1007/978-1-4614-7138-7](https://doi.org/10.1007/978-1-4614-7138-7). Citado nas pp. 36, 38, 53, 57 e 61.
- KILLICK, R.; FEARNHEAD, P.; ECKLEY, I. A. Optimal detection of changepoints with a linear computational cost. **Journal of the American Statistical Association**, v. 107, n. 500, p. 1590–1598, 2012. DOI [10.1080/01621459.2012.737745](https://doi.org/10.1080/01621459.2012.737745). Citado na p. 87.
- KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. In: **3rd International Conference on Learning Representations (ICLR 2015)**. San Diego, CA, USA: International Conference on Learning Representations, 2015. Disponível em: <http://arxiv.org/abs/1412.6980>. Citado na p. 65.
- LU, Y. Industry 4.0: A survey on technologies, applications and open research issues. **Journal of Industrial Information Integration**, v. 6, p. 1–10, 2017. DOI [10.1016/j.jii.2017.04.005](https://doi.org/10.1016/j.jii.2017.04.005). Citado na p. 17.
- LUNDBERG, S. M.; ERION, G. G.; CHEN, H.; DEGRAVE, A.; PRUTSMAN, J. M.; NAIR, B.; KATZ, R.; HIMMELFARB, J.; BANSAL, N.; LEE, S.-I. From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, v. 2, n. 1, p. 56–67, 2020. DOI [10.1038/s42256-019-0138-9](https://doi.org/10.1038/s42256-019-0138-9). Citado nas pp. 58 e 67.
- LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems**. Long Beach, CA, USA: Curran Associates, 2017. v. 30. Disponível em: <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>. Citado nas pp. 19 e 66.
- MACHADO, A. P. F. **Methodologies to Improve One-Class Classifier Performance Applied to Multivariate Time Series**. Tese (Doutorado) — Departamento de Engenharia Elétrica, Universidade Federal do Espírito Santo, Espírito Santo, Brasil, 2024. Citado na p. 20.
- MITCHELL, T. M. **Machine Learning**. [S.L.]: McGraw-Hill, 1997. ISBN 978-0-07-042807-2. Citado na p. 18.

- NORTHCUTT, C. G.; JIANG, L.; CHUANG, I. L. Confident learning: Estimating uncertainty in dataset labels. **Journal of Artificial Intelligence Research**, v. 70, p. 1373–1411, 2021. DOI [10.1613/jair.1.12125](https://doi.org/10.1613/jair.1.12125). Citado na p. 87.
- OLIVEIRA, M. C. K. de; GONÇALVES, M. de A. L.; MARQUES, L. C. do C. **Fundamentos de Garantia de Escoamento**. 1. ed. Rio de Janeiro: Interciência, 2018. ISBN 978-85-7193-429-0. Citado na p. 18.
- OPPENHEIM, A. V.; SCHAFER, R. W. **Discrete-Time Signal Processing**. 3. ed. [S.l.]: Pearson, 2009. ISBN 978-0-13-198842-2. Citado nas pp. 55 e 56.
- PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COURNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY, É. Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>. Citado na p. 58.
- ROSA, R. L. **Classificação de Eventos Indesejáveis na Produção de Petróleo Offshore com Aplicação de Técnicas de Inteligência Artificial**. Monografia (Trabalho de Conclusão de Curso (Bacharelado em Engenharia de Produção)) — Universidade Federal Fluminense (UFF), Niterói, 2020. Orientador: Gilson Brito Alves Lima. Citado na p. 20.
- RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 4. ed. [S.l.]: Pearson, 2020. ISBN 978-0-13-461099-3. Citado na p. 18.
- SIRCAR, A.; YADAV, K.; RAYAVARAPU, K.; BIST, N.; OZA, H. Application of machine learning and artificial intelligence in oil and gas industry. **Petroleum Research**, v. 6, n. 4, p. 379–391, 2021. DOI [10.1016/j.ptlrs.2021.05.009](https://doi.org/10.1016/j.ptlrs.2021.05.009). Citado na p. 17.
- SLOAN, E. D.; KOH, C. A. **Clathrate Hydrates of Natural Gases**. 3. ed. [S.l.]: CRC Press, 2008. ISBN 978-0-8493-9078-4. DOI [10.1201/9781420008494](https://doi.org/10.1201/9781420008494). Citado na p. 18.
- SRIVASTAVA, N.; HINTON, G.; KRIZHEVSKY, A.; SUTSKEVER, I.; SALAKHUTDINOV, R. Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 1, p. 1929–1958, 2014. Disponível em: <http://jmlr.org/papers/v15/srivastava14a.html>. Citado na p. 53.
- VARGAS, R. E. V.; MUNARO, C. J.; CIARELLI, P. M.; MEDEIROS, A. G.; AMARAL, B. G.; BARRIONUEVO, D. C.; ARAUJO, J. C.; RIBEIRO, J. L.; MAGALHÃES, L. P. A realistic and public dataset with rare undesirable real events in oil wells. **Journal of Petroleum Science and Engineering**, v. 181, p. 106223, 2019. DOI [10.1016/j.petrol.2019.106223](https://doi.org/10.1016/j.petrol.2019.106223). Citado nas pp. 17, 26 e 30.

- VARGAS, R. E. V.; MUNARO, C. J.; CIARELLI, P. M.; MEDEIROS, A. G.; AMARAL, B. G.; BARRIONUEVO, D. C.; ARAUJO, J. C.; RIBEIRO, J. L.; MAGALHÃES, L. P.; CARVALHO, M. A.; GONÇALVES, R. A.; SILVA, D. S.; CRUZ, E. S.; SOUZA, F. M. **3W Dataset 2.0.0: A Realistic and Public Dataset with Rare Undesirable Real Events in Oil Wells**. 2025. ArXiv preprint. DOI [10.48550/arXiv.2507.01048](https://doi.org/10.48550/arXiv.2507.01048). Citado nas pp. 22, 24, 25 e 26.
- VIRTANEN, P.; GOMMERS, R.; OLIPHANT, T. E.; HABERLAND, M.; REDDY, T.; COURNAPEAU, D.; BUROVSKI, E.; PETERSON, P.; WECKESSER, W.; BRIGHT, J.; WALT, S. J. van der; BRETT, M.; WILSON, J.; MILLMAN, K. J.; MAYOROV, N.; NELSON, A. R. J.; JONES, E.; KERN, R.; LARSON, E.; CAREY, C. J.; POLAT, İ.; FENG, Y.; MOORE, E. W.; VANDERPLAS, J.; LAXALDE, D.; PERKTOLD, J.; CIMRMAN, R.; HENRIKSEN, I.; QUINTERO, E. A.; HARRIS, C. R.; ARCHIBALD, A. M.; RIBEIRO, A. H.; PEDREGOSA, F.; MULBREGT, P. van. SciPy 1.0: Fundamental algorithms for scientific computing in Python. **Nature Methods**, v. 17, p. 261–272, 2020. DOI [10.1038/s41592-019-0686-2](https://doi.org/10.1038/s41592-019-0686-2). Citado na p. 58.
- WANG, Z.; YAN, W.; OATES, T. Time series classification from scratch with deep neural networks: A strong baseline. In: **2017 International Joint Conference on Neural Networks (IJCNN)**. Anchorage, AK, USA: IEEE, 2017. p. 1578–1585. DOI [10.1109/IJCNN.2017.7966039](https://doi.org/10.1109/IJCNN.2017.7966039). Citado nas pp. 19, 50, 65 e 95.

Apêndices

Apêndice A – Hiperparâmetros Otimizados

Este apêndice apresenta os hiperparâmetros selecionados para os quatro modelos avaliados: RF e XGBoost, otimizados por busca aleatória (*RandomizedSearchCV*); CNN-LSTM, otimizada por *Optuna*; e CNN-1D (FCN), com arquitetura fixa.

A.1 Random Forest e XGBoost

A Tabela A.1 apresenta o espaço de busca utilizado na estratégia Nested CV para os dois modelos baseados em árvore.

Tabela A.1 – Espaços de busca de hiperparâmetros por modelo.

Modelo	Hiperparâmetro	Valores candidatos
RF	n_estimators	100, 200, 300
RF	max_depth	Sem limite, 10, 20, 30
RF	min_samples_leaf	1, 2, 4
RF	max_features	'sqrt', 'log2'
XGBoost	n_estimators	100, 200, 300, 500
XGBoost	max_depth	3, 4, 6, 8
XGBoost	learning_rate	0,01; 0,05; 0,1; 0,2
XGBoost	subsample	0,7; 0,8; 1,0
XGBoost	colsample_bytree	0,7; 0,8; 1,0
XGBoost	min_child_weight	1, 3, 5

A.2 CNN-LSTM

Os hiperparâmetros da CNN-LSTM foram otimizados com *Optuna* (30 trials, *Median-Pruner*), utilizando o *fold 0* do *GroupKFold* como conjunto de validação interna. A Tabela A.2 apresenta o espaço de busca e os valores selecionados.

Tabela A.2 – Espaço de busca e hiperparâmetros selecionados pelo *Optuna* (CNN-LSTM).

Hiperparâmetro	Espaço de busca	Selecionado
<code>lstm_units</code>	categórico: {32, 64, 128}	128
<code>dropout_rate</code>	contínuo: [0,1; 0,5]	0,24
<code>learning_rate</code>	log-uniforme: [10^{-4} ; 10^{-2}]	$1,09 \times 10^{-3}$
<code>batch_size</code>	categórico: {256, 512}	512

A arquitetura da CNN-LSTM é fixa: dois blocos Conv1D+BN+ReLU+MaxPool reduzem a sequência de 300 para 75 *timesteps*, seguidos por uma camada LSTM e *Dropout*. O melhor *trial* atingiu F1-macro de validação de 0,762.

A.3 CNN-1D (FCN)

A CNN-1D segue a arquitetura FCN (*Fully Convolutional Network*) proposta por Wang, Yan e Oates (2017), com hiperparâmetros fixos sem etapa de busca. A Tabela A.3 detalha as camadas e configurações utilizadas.

Tabela A.3 – Arquitetura e configurações da CNN-1D (FCN).

Componente	Configuração
Conv1D + BN + ReLU	128 filtros, <i>kernel</i> = 8
Conv1D + BN + ReLU	256 filtros, <i>kernel</i> = 5
Conv1D + BN + ReLU	128 filtros, <i>kernel</i> = 3
GlobalAveragePooling1D	—
Dense (<i>softmax</i>)	17 classes
Otimizador	Adam, $lr = 1 \times 10^{-3}$
<i>Batch size</i>	512
Épocas máximas	100 (com <i>EarlyStopping</i>)

Apêndice B – Distribuição das Classes no Conjunto de Dados

A Tabela B.1 apresenta a distribuição completa das 449.397 janelas deslizantes extraídas das 1.409 instâncias do 3W Dataset, após o processo de pré-processamento e rotulagem descrito no Capítulo 4. Para cada um dos 17 estados operacionais, são informados o número de janelas e a porcentagem em relação ao total.

Tabela B.1 – Distribuição das janelas por estado operacional (filtro Gaussiano, $\sigma = 2,0$).

Classe	Evento (Estado)	Janelas	%
0	Normal	102.040	22,71
1	BSW (Ativo)	19.305	4,30
2	DHSV (Ativo)	2.409	0,54
3	Golfadas (Ativo)	32.105	7,14
4	Inst. Fluxo (Ativo)	12.238	2,72
5	Prod. Rápida (Ativo)	70.018	15,58
6	PCK Restr. (Ativo)	25.645	5,71
7	PCK Incrust. (Ativo)	914	0,20
8	Hidrato Prod. (Ativo)	4.817	1,07
9	Hidrato Serv. (Ativo)	21.122	4,70
101	BSW (Trans.)	34.991	7,79
102	DHSV (Trans.)	937	0,21
105	Prod. Rápida (Trans.)	16.045	3,57
106	PCK Restr. (Trans.)	10.181	2,27
107	PCK Incrust. (Trans.)	48.982	10,90
108	Hidrato Prod. (Trans.)	27.934	6,22
109	Hidrato Serv. (Trans.)	19.714	4,39
Total		449.397	100,00

O conjunto é fortemente desbalanceado: as três classes mais frequentes (Normal, Prod. Rápida Ativo e PCK Incrust. Trans.) concentram juntas 49,2% das janelas, enquanto as classes mais raras (PCK Incrust. Ativo e DHSV Trans.) representam menos de 0,25% cada. Esse desbalanceamento justifica o uso de pesos de classe no treinamento e o F1-macro como métrica principal de avaliação, conforme discutido nas Seções ?? e ??.

Apêndice C – Valores SHAP para Todas as Classes Operacionais

Este apêndice reúne os gráficos de valores SHAP para todas as 17 classes operacionais. Em cada figura, o painel esquerdo corresponde ao RF e o direito ao XGBoost. Os pontos são coloridos pelo valor normalizado da feature (azul = baixo, vermelho = alto) e ordenados pela importância média absoluta no modelo XGBoost.

C.1 Estados Ativos

Figura C.1 – Valores SHAP para a classe 0 (Normal) — RF vs XGBoost.




Figura C.2 – Valores SHAP para a classe 1 (BSW, Ativo) — RF vs XGBoost.




Figura C.3 – Valores SHAP para a classe 2 (DHSV, Ativo) — RF vs XGBoost.




Figura C.4 – Valores SHAP para a classe 3 (Golfadas, Ativo) — RF vs XGBoost.




Figura C.5 – Valores SHAP para a classe 4 (Instabilidade de Fluxo, Ativo) — RF vs XGBoost.




Figura C.6 – Valores SHAP para a classe 5 (Perda Rápida de Produtividade, Ativo) — RF vs XGBoost.




Figura C.7 – Valores SHAP para a classe 6 (Restrição no PCK, Ativo) — RF vs XGBoost.




Figura C.8 – Valores SHAP para a classe 7 (Incrustação no PCK, Ativo) — RF vs XGBoost.




Figura C.9 – Valores SHAP para a classe 8 (Hidrato na Linha de Produção, Ativo) — RF vs XGBoost.





Figura C.10 – Valores SHAP para a classe 9 (Hidrato na Linha de Serviço, Ativo) — RF vs XGBoost.



C.2 Estados Transientes

Figura C.11 – Valores SHAP para a classe 101 (BSW, Transiente) — RF vs XGBoost.




Figura C.12 – Valores SHAP para a classe 102 (DHSV, Transiente) — RF vs XGBoost.




Figura C.13 – Valores SHAP para a classe 105 (Perda Rápida de Produtividade, Transiente) — RF vs XGBoost.




Figura C.14 – Valores SHAP para a classe 106 (Restrição no PCK, Transiente) — RF vs XGBoost.




Figura C.15 – Valores SHAP para a classe 107 (Incrustação no PCK, Transiente) — RF vs XGBoost.




Figura C.16 – Valores SHAP para a classe 108 (Hidrato na Linha de Produção, Transiente) — RF vs XGBoost.




Figura C.17 – Valores SHAP para a classe 109 (Hidrato na Linha de Serviço, Transiente) — RF vs XGBoost.




Figura D.2 – Matriz de confusão do XGBoost (filtro Gaussiano, $\sigma = 2,0$).




Figura D.3 – Matriz de confusão do XGBoost (sem filtro).




Figura D.4 – Matriz de confusão do XGBoost (filtro estatístico, $\sigma = 0,5$).




Figura D.5 – Matriz de confusão da CNN-LSTM (filtro Gaussiano, $\sigma = 2,0$).




Figura D.6 – Matriz de confusão da CNN-LSTM (filtro estatístico, $\sigma = 0,5$).





Figura D.7 – Matriz de confusão da CNN-1D (FCN, filtro Gaussiano, $\sigma = 2,0$).





UnB